

Statistiques mathématiques

R. Petit

année académique 2016 - 2017

Table des matières

1	Théorie de l'échantillonnage	2
1.1	Terminologie et définitions	2
1.2	Moments	3
1.2.1	Indicateurs	4
1.3	Quantile	4
1.3.1	Lemme de Fisher	6
2	Estimation ponctuelle	8
2.1	Introduction	8
2.2	Critères d'estimation	8
2.2.1	Définitions de convergence	8
2.2.2	Résultats élémentaires sur les convergences	9
2.2.3	Estimateurs convergents	10
2.3	Estimateur exhaustif	11
2.3.1	Estimateurs non biaisés	13
2.3.2	Estimateurs à dispersion minimale	14
2.3.3	Estimateurs efficaces	19
2.4	Méthodes d'estimation	23
2.4.1	Méthode des moments	23
2.4.2	Méthode du maximum de vraisemblance	25
2.4.3	Comportement asymptotique des estimateurs du maximum de vraisemblance	27
3	Tests d'hypothèse	30
3.1	Principe de Neyman	31
3.2	Tests unilatéraux à puissance uniformément maximale	34
3.3	Tests bilatéraux	35
3.3.1	Tests sans biais	36
3.4	Tests de rapport de vraisemblance	36
3.5	Tests χ^2	37
3.5.1	Loi multinomiale	37
3.5.2	Tests d'ajustement et d'adéquation	38
3.5.3	Tests d'homogénéité	39
3.5.4	Tests d'indépendance	39

Introduction

En probabilités, une variable aléatoire X donnée est entièrement définie par sa loi. On peut l'exprimer par la fonction de répartition F^X ou par la fonction de densité $f^X = \frac{d}{dx} F^X$. Ces fonctions permettent de déterminer :

$$\mathbb{P}[a \leq X \leq b] = \int_a^b f^X(x) dx = F^X(b) - F^X(a).$$

Ou encore :

$$\mathbb{E}[X] = \int_{-\infty}^{+\infty} x f^X(x) dx.$$

Cependant, les fonctions f^X et F^X ne sont jamais connues précisément. Elles peuvent être approchées par des modélisations, mais les modèles ne sont jamais exacts. En probabilités, on cherche donc les observations sur base de la loi qui est connue, alors qu'en statistiques, on cherche à retrouver la loi sur base de n observations X_1, \dots, X_n .

Nous allons nous intéresser à des *modèles statistiques* sous la forme $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), \mathcal{P}^{(n)})$ où :

$$\mathcal{P}^{(n)} = \left\{ \mathbb{P}^{(n)} \right\} = \left\{ \mathbb{P}_\theta^{(n)} \text{ t.q. } \theta \in \Theta \subset \mathbb{R}^k \right\},$$

et donc les $\mathbb{P}^{(i)}$ sont chacun une loi possible pour (X_1, \dots, X_n) .

Ces modèles sont dits *paramétriques* car les différentes lois sont les mêmes au paramètre θ près. Nous n'étudierons que des modèles paramétriques où Θ est un espace de dimension $d \in \mathbb{N}$ finie.

Exemple 0.1. Soient X_1, \dots, X_n des variables aléatoires iid (indépendantes et identiquement distribuées).

— Si les X_i sont de loi normale $\mathcal{N}(\mu, \sigma^2)$, alors le paramètre θ est donné par :

$$\theta = \begin{pmatrix} \mu \\ \sigma^2 \end{pmatrix} \in \Theta = \mathbb{R} \times \mathbb{R}^+ \subset \mathbb{R}^2;$$

— si les X_i sont de loi uniforme $\text{Unif}(0, \theta)$, le paramètre θ est donné par $\theta \in \Theta = \mathbb{R}_0^+ \subset \mathbb{R}$;

— si les X_i sont de loi Bern(p), le paramètre θ est donné par $\theta = p \in \Theta = [0, 1] \subset \mathbb{R}$.

Remarque. Une loi normale $\mathcal{N}(\mu, \sigma^2)$ est déraisonnable car les valeurs observables ne vont empiriquement pas vers les infinis alors que la distribution le permet théoriquement mais n'est pas **complètement** déraisonnable car ces probabilités sont négligeables grâce à l'exponentielle de $(-x^2)$ dans la formule de la densité.

Chapitre 1

Théorie de l'échantillonnage

1.1 Terminologie et définitions

Définition 1.1. On appelle *modèle d'échantillonnage* un modèle d'observations iid.

Définition 1.2. Soit un modèle statistique $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), \mathcal{P}^{(n)})$ où $\mathcal{P}^{(n)} = \{\mathbb{P}_\theta^{(n)} \text{ t.q. } \theta \in \Theta \subset \mathbb{R}^k\}$. On note ici $\mathbb{P}_\theta^{(n)}$ une loi possible pour (X_1, \dots, X_n) et \mathbb{P}_θ une loi possible pour X_i avec i fixé. On dit alors que $\mathbb{P}_\theta^{(n)}$ est déterminé par \mathbb{P}_θ .

Remarque. Ici, deux visions vont s'opposer et se compléter : la vision *population* qui est associée à \mathbb{P}_θ et la version *échantillonnage* (ou *empirique*), qui, elle, est associée à $\mathbb{P}_\theta^{(n)}$.

Définition 1.3. On définit la fonction indicatrice $I_{[\cdot]}$ qui vaut 1 quand l'expression entre crochets est vraie et 0 sinon.

Définition 1.4. Soit X_1, \dots, X_n une suite de n observations. On définit la *ième statistique d'ordre* par $X_{(i)} = X_k$ t.q. $|\{X_j \text{ t.q. } X_j < X_k, 1 \leq j \leq n\}| = i$. On définit également la *statistique d'ordre* par $(X_{(i)})_i$.

Définition 1.5. On définit les fonctions de répartition comme suit :

— la fonction de répartition population :

$$F_\theta(x) = \mathbb{P}_\theta[X_i \leq x] ;$$

— la fonction de répartition empirique :

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I_{[X_i \leq x]}.$$

Remarque. La fonction F_n empirique est une fonction en escaliers. Elle fait des sauts de hauteur $\frac{1}{n}$, et est telle que :

$$\lim_{x \rightarrow +\infty} F_n(x) = 1 \quad \text{et} \quad \lim_{x \rightarrow -\infty} F_n(x) = 0.$$

On peut également remarquer que $F_n(X_{(i)}) = \frac{i}{n}$. En effet, par définition de $X_{(i)}$, il y a exactement i observations inférieures à $X_{(i)}$. Dès lors, la fonction indicatrice donnera i fois la valeur 1 et $(n - i)$ fois la valeur 0. La somme donc i et la fonction donne $\frac{i}{n}$.

Définition 1.6. On appelle *statistique* toute fonction mesurable faisant intervenir **uniquement** des observations.

Exemple 1.1. Par exemple F_n est une statistique car seules les valeurs X_i sont utilisées, mais F_θ n'est pas une statistique car la valeur du paramètre θ apparaît et n'est pas une observation.

Remarque. Une statistique peut être à valeur scalaire ($X_{(i)}$ par exemple), à valeur vectorielle ($(X_{(i)})_{1 \leq i \leq n}$ par exemple), à valeur ensembliste ($[X_i \pm \bar{X}]$ avec i fixé par exemple), ou encore à valeur fonctionnelle (F_n par exemple).

Remarque. L'objectif est de pouvoir approximer la loi régissant les populations (F_θ) à l'aide de la loi observée empiriquement. Par la loi des grands nombres, on a :

$$F_n(x) \xrightarrow[n \rightarrow +\infty]{\text{p.s. par } \mathbb{P}_\theta} F_\theta(x).$$

Théorème 1.7 (Théorème de Glivenko-Cantelli). Si F_n et F_θ sont respectivement une fonction de répartition empirique et de population, alors :

$$\sup_{x \in \mathbb{R}} |F_n(x) - F_\theta(x)| \xrightarrow[n \rightarrow +\infty]{\text{p.s.}} 0$$

1.2 Moments

Définition 1.8 (Moments pour populations). On définit $\mu'_r(\theta)$ le *moment non-centré* d'ordre r avec $r \in \mathbb{N}^*$ par :

$$\mu'_r(\theta) := E_\theta[X_1^r].$$

On définit également $\mu_r(\theta)$, le *moment centré* d'ordre r avec $r \in \mathbb{N}^*$ par :

$$\mu_r(\theta) := E_\theta \left[(X_1 - \mu'_r(\theta))^r \right].$$

Définition 1.9 (Moments pour échantillon). On définit m'_r , le *moment non-centré* d'ordre r avec $r \in \mathbb{N}^*$ par :

$$m'_r := \frac{1}{n} \sum_{i=1}^n X_i^r.$$

On définit également le *moment centré* d'ordre r avec $r \in \mathbb{N}^*$ par :

$$m_r := \frac{1}{n} \sum_{i=1}^n (X_i - m'_r)^r.$$

Remarque. La loi des grands nombres dit que :

$$m'_r \xrightarrow[n \rightarrow +\infty]{\text{p.s.}} \mu'_r(\theta),$$

mais on ne peut pas dire que :

$$m_r \xrightarrow[n \rightarrow +\infty]{\text{p.s.}} \mu_r(\theta).$$

Ce n'est donc pas possible car pour m'_r , il y a une somme de variables iid alors que pour m_r , les variables sommées ne sont pas iid (mais dépendent toutes de tous les X_i).

En réalité, il y a convergence, mais on ne peut pas l'exprimer de manière triviale par la loi des grands nombres.

1.2.1 Indicateurs

On peut observer que $\mu'_1(\theta) = \mathbb{E}_\theta[X_1]$. Pareil pour $m'_1 = \bar{X}$. Le moment d'ordre 1 est donc un indice de position. On a alors $\mu := \mu_1(\theta) = \mathbb{E}[(X - \mathbb{E}[X_1])] = \mathbb{E}[X_1] - \mathbb{E}[X_1] = 0$. Cette valeur n'est donc pas intéressante. Par contre :

$$\mu_2(\theta) = \mathbb{E}[(X_1 - \mathbb{E}[X_1])^2] =: \text{Var}(X) \quad \text{si} \quad m_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 =: s^2.$$

Le moment d'ordre 2 est donc un indice de dispersion.

Définition 1.10. On appelle le *coefficient d'asymétrie de Fisher* la quantité :

$$\gamma_1 := \mu_3(\theta) \cdot (\mu_2(\theta))^{-\frac{3}{2}}.$$

Remarque. Le dénominateur $\mu_2(\theta)^{\frac{3}{2}}$ apparait afin de rendre invariant le coefficient d'asymétrie de Fisher aux transformations affines.

Définition 1.11. Le coefficient d'asymétrie de Fisher *empirique* est donné par :

$$m_3 \cdot m_2^{-\frac{3}{2}}.$$

Définition 1.12. On appelle *coefficient d'aplatissement de Fisher* la quantité :

$$\gamma_2 := \mu_4(\theta) \cdot (\mu_2(\theta))^{-2} - 3.$$

Définition 1.13. Le coefficient d'aplatissement de Fisher *empirique* est donné par :

$$m_4 \cdot m_2^{-2} - 3.$$

Remarque. Si $\gamma_2 \geq 0$, c'est que les événements extrêmes sont de plus haute probabilité et si $\gamma_2 \leq 0$, c'est que les événements extrêmes sont de moins haute probabilité.

À nouveau, le dénominateur y a été ajouté afin de rendre le coefficient invariant aux transformations affines. Et le terme -3 sert à annuler le coefficient d'aplatissement de Fisher pour une normale $\mathcal{N}(\mu, \sigma^2)$.

1.3 Quantile

Définition 1.14. Si F_θ est inversible, alors on définit $x_\alpha(\theta) := F_\theta^{-1}(\alpha)$, et on appelle $x_\alpha(\theta)$ un *quantile*.

Remarque. Il faut cependant faire attention car on peut avoir le cas de F_θ discontinue où on choisit $\alpha = F_\theta^{-1}$ (point de discontinuité) ou alors le cas de F_θ admettant un plateau et où on choisit α sur le plateau.

Définition 1.15. On définit alors :

$$x_\alpha(\theta) := \inf \{x \in \mathbb{R} \text{ t.q. } F_\theta(x) \geq \alpha\}.$$

Remarque. On donne les noms de *médiane*, *quartile*, *décile*, *percentile* pour α valant, avec k entier, respectivement $\frac{1}{2}$, $\frac{k}{4}$ avec $k < 4$, $\frac{k}{10}$ avec $k < 10$, et $\frac{k}{100}$ avec $k < 100$.

Définition 1.16. Pour les échantillons, on définit le *quantile empirique d'ordre α* par :

$$x_\alpha^{(n)} := \inf \{x \in \mathbb{R} \text{ t.q. } F_n(x) \geq \alpha\}.$$

Remarque. On peut également définir des indices de position, dispersion, asymétrie, aplatissement, etc. sur les quantiles plutôt que sur les moments. Ils auront des propriétés différentes et une robustesse différente aux valeurs aberrantes.

Définition 1.17. La loi échantillonnée de $T(X^{(n)})$ est la loi déterminée par :

$$\mathbb{P}_\theta^{(n)} \left[T(X^{(n)}) \in B \right] = \mathbb{P}_\theta^{(n)} \left[\left\{ x^{(n)} \in \mathcal{X}^{(n)} \text{ t.q. } T(x^{(n)}) \in B \right\} \right], B \in \mathcal{B}(\mathbb{R}^m).$$

Exemple 1.2 (Bernoulli). $X^{(n)} = (X_1, \dots, X_n)$ où les X_i sont iid $\text{Bern}(p)$. On a alors : $T(X^{(n)}) = \sum_{i=1}^n X_i$, sous $\mathbb{P}_\theta^{(n)}$, est de loi $\text{Bin}(n, p)$.

Exemple 1.3 (Normale). $X^{(n)} = (X_1, \dots, X_n)$ où les X_i sont iid $\mathcal{N}(\mu, \sigma^2)$ et où $\theta = \begin{pmatrix} \mu \\ \sigma^2 \end{pmatrix} \in \Theta = \mathbb{R} \times \mathbb{R}_0^+ \subset \mathbb{R}^2$.

La statistique $T_1(X^{(n)}) = \sum_{i=1}^n X_i$, sous $\mathbb{P}_\theta^{(n)}$, est de loi $\mathcal{N}(n\mu, n\sigma^2)$.

La statistique $T_2(X^{(n)}) = \frac{1}{n} \sum_{i=1}^n X_i$, sous $\mathbb{P}_\theta^{(n)}$, est de loi $\mathcal{N}(\mu, \frac{\sigma^2}{n})$.

Exemple 1.4 (Uniforme). $X^{(n)} = (X_1, \dots, X_n)$ où les X_i sont iid $\text{Unif}(0, \theta)$, pour $\theta \in \Theta = \mathbb{R}_0^+ \subset \mathbb{R}$. On a donc $f_\theta^{X_i}(x) = \theta^{-1} I_{[0 \leq x \leq \theta]}$. Et donc :

$$F_\theta^{X_i}(x) = \begin{cases} 0 & \text{si } x < 0 \\ \frac{x}{\theta} & \text{si } 0 \leq x \leq \theta \\ 1 & \text{sinon} \end{cases}.$$

La statistique $T(X^{(n)}) = X_{(n)} = \max_{1 \leq k \leq n} \{X_k\}$ a pour fonction de répartition, sous $\mathbb{P}_\theta^{(n)}$:

$$F_\theta^{(n)}(x) = \mathbb{P}[X_{(n)} \leq x] = \mathbb{P}[X_1 \leq x, X_2 \leq x, \dots, X_n \leq x].$$

La seconde forme est plus agréable car on a une intersection d'événements indépendants. Donc :

$$F_\theta^{(n)}(x) = \prod_{i=1}^n \mathbb{P}[X_i \leq x] = \prod_{i=1}^n F_\theta^{X_i}(x) = \begin{cases} 0 & \text{si } x < 0 \\ \left(\frac{x}{\theta}\right)^n & \text{si } 0 \leq x \leq \theta \\ 0 & \text{sinon} \end{cases}.$$

On a alors la fonction de densité :

$$\begin{aligned} f_\theta^{X_{(n)}}(x) &= \frac{d}{dx} F_\theta^{X_{(n)}} \Big|_x = \begin{cases} 0 & \text{si } x < 0 \\ \frac{nx^{n-1}}{\theta^n} I_{[0 \leq x \leq \theta]} & \text{si } 0 \leq x \leq \theta \\ 0 & \text{sinon} \end{cases} \\ &= \frac{nx^{n-1}}{\theta^n} I_{[0 \leq x \leq \theta]}. \end{aligned}$$

Remarque. La loi échantillonnée n'est pas toujours possible à déterminer exactement analytiquement. Dans ce cas, on donne :

- (i) les/des moments de la loi échantillonnée exacte ;
- (ii) la loi échantillonnée asymptotique.

Et pour de grandes valeurs de n , la loi asymptotique donne une assez bonne approximation de la loi exacte.

Remarque. Ici, les termes *exact* et *asymptotique* s'opposent : on parle d'objet *exact* lorsque l'objet est connu pour n fixé, et d'objet *asymptotique* lorsque l'objet n'est connu que pour $n \rightarrow +\infty$.

Exemple 1.5. Voici un cas où on ne peut exprimer de loi exacte mais où il est possible d'exprimer une loi asymptotique. Soit $X^{(n)} = (X_1, \dots, X_n)$ où les X_i sont iid F avec la fonction F telle que $\text{Var}_F(X_i) = \sigma^2 < +\infty$ et donc $E_F(X_i) = \mu < +\infty$. On peut dès lors appliquer le théorème central limite (TCL) :

$$\sqrt{n}(\bar{X}^{(n)} - \mu) \xrightarrow[n \rightarrow +\infty]{\mathcal{D}} \mathcal{N}(0, \sigma^2).$$

Pour $n \gg$, on peut alors dire :

$$\bar{X}^{(n)} \approx \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right),$$

où le symbole \approx se lit *est à peu près de même loi*.

On en conclut donc qu'avec n suffisamment grand, on peut approximer $\bar{X}^{(n)}$, même sans connaître sa loi exacte.

1.3.1 Lemme de Fisher

Définition 1.18. La variable aléatoire Q est de loi χ^2 (chi-carrée) à $k(\in \mathbb{N}^*)$ degrés de liberté lorsque :

$$Q \stackrel{\mathcal{D}}{=} \sum_{i=1}^k Z_i^2,$$

où les Z_i sont iid $\mathcal{N}(0, 1)$ et où « $\stackrel{\mathcal{D}}{=}$ » veut dire *à la même distribution que*. Cela se note :

$$Q \sim \chi_k^2$$

Remarque. Si $Q \sim \chi_k^2$, alors :

$$f^Q(x) = \frac{1}{2^{\frac{k}{2}} \Gamma\left(\frac{k}{2}\right)} x^{\frac{k}{2}-1} \exp\left(-\frac{x}{2}\right) I_{[x>0]},$$

où Γ est la fonction Gamma d'Euler définie par :

$$\Gamma(x) = \int_0^{+\infty} t^{x-1} \exp(-t) dt.$$

De plus, $\text{Var}(Q) = 2k$, et $\mathbb{E}(Q) = k$.

On peut également noter que les χ^2 sont stables par la somme : si $Q_1 \sim \chi_{k_1}^2$ et $Q_2 \sim \chi_{k_2}^2$, alors :

$$Q_1 + Q_2 \sim \chi_{k_1+k_2}^2.$$

Lemme 1.19. Soit $W = (W_1, \dots, W_k)$ un vecteur de variables aléatoires, où $f^W : \mathbb{R}^k \rightarrow \mathbb{R}^+$ est la fonction de densité du vecteur W . Alors :

1. $\mathbb{P}[W \in B] = \int_B f^W(x) dx$;
2. si $V = AW + b$ où A est une matrice $k \times k$ inversible, alors :

$$f^V(v) = \left| \det A^{-1} \right| f^W\left(A^{-1}(v - b)\right).$$

Théorème 1.20 (Lemme de Fisher). Soient X_1, \dots, X_n iid $\mathcal{N}(\mu, \sigma^2)$ où $n \geq 2$. Alors :

- (i) $\bar{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$;
- (ii) $\frac{ns^2}{\sigma^2} \sim \chi_{n-1}^2$;
- (iii) $\bar{X} \perp s^2$.

Démonstration. Posons $Z_i := \frac{X_i - \mu}{\sigma}$ pour $i \in \llbracket 1, n \rrbracket$. Puisque les X_i sont iid, les Z_i le sont également (même transformation appliquée à tous les X_i et chaque Z_i ne fait intervenir que le X_i correspondant). Notons que :

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{n} \sum_{i=1}^n (\sigma Z_i + \mu) = \sigma \bar{Z} + \mu,$$

où \bar{Z} est la moyenne empirique des Z_i . Notons également que :

$$ns^2 = \sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n \left((\sigma Z_i + \mu) - (\sigma \bar{Z} + \mu) \right)^2 = \sigma^2 \sum_{i=1}^n (Z_i - \bar{Z})^2 = n\sigma^2 s_Z^2.$$

Il nous faut alors montrer que $\bar{Z} \sim \mathcal{N}(0, 1)$ et $ns_Z^2 \sim \chi_{n-1}^2$, avec $\bar{Z} \sqcup s_Z^2$.

Pour cela, on sait que le vecteur $Z^{(n)} = (Z_1, \dots, Z_n)$ a pour densité :

$$f^{Z^{(n)}}(z^{(n)}) = \prod_{i=1}^n f^{Z_i}(z_i) = \prod_{i=1}^n \left(\frac{1}{\sqrt{2\pi}} \exp\left(-\frac{z_i^2}{2}\right) \right) = \left(\frac{1}{\sqrt{2\pi}} \right)^n \exp\left(-\sum_{i=1}^n \frac{z_i^2}{2}\right) = \left(\frac{1}{\sqrt{2\pi}} \right)^n \exp\left(-\frac{1}{2} \|z^{(n)}\|^2\right).$$

Soit O une matrice orthogonale de dimension $n \times n$ telle que $\forall j \in \llbracket 1, n \rrbracket : O_{1j} = \frac{1}{\sqrt{n}}$. On pose alors :

$$(Y_1, \dots, Y_n) = Y^{(n)} = OZ^{(n)}.$$

Puisque la matrice O est orthogonale, on sait que O^{-1} existe et que $|\det O| = |\det O^{-1}| = 1$. Par le lemme 1.19, on peut dire :

$$f^{Y^{(n)}}(y^{(n)}) = |\det O^{-1}| f^{Z^{(n)}}(O^{-1}y^{(n)}) = \left(\frac{1}{\sqrt{2\pi}} \right)^n \exp\left(-\frac{1}{2} \|O^{-1}y^{(n)}\|^2\right) = \left(\frac{1}{\sqrt{2\pi}} \right)^n \exp\left(-\frac{1}{2} \|y^{(n)}\|^2\right).$$

On a donc $f^{Y^{(n)}} = f^{Z^{(n)}}$, ce qui implique que les Y_i sont iid $\mathcal{N}(0, 1)$.

En particulier, $Y_1 = (Y^{(n)})_1 = (OZ^{(n)})_1 = \sum_{i=1}^n O_{1i}Z_i = \sum_{i=1}^n \frac{Z_i}{\sqrt{n}} = \sqrt{n}\bar{Z} \sim \mathcal{N}(0, 1)$. On peut alors en déduire que $\bar{Z} \sim \mathcal{N}(0, n^{-1})$.

Montrons alors que $ns_Z^2 \sim \chi_{n-1}^2$:

$$ns_Z^2 = \sum_{i=1}^n (Z_i - \bar{Z})^2 = \sum_{i=1}^n Z_i^2 - n(\bar{Z})^2 = \|Z^{(n)}\|^2 - (\sqrt{n}\bar{Z})^2 = \|Y^{(n)}\|^2 - Y_1^2 = \sum_{i=2}^n Y_i^2.$$

Or, les Y_i sont $\mathcal{N}(0, 1)$. On a alors bien $ns_Z^2 \sim \chi_{n-1}^2$ (car la somme sur i commence à 2, il y a donc $(n-1)$ variables sommées).

De plus, puisque les Y_i sont indépendantes deux à deux, que \bar{Z} ne dépend que de Y_1 et que ns_Z^2 ne dépend pas de Y_1 , on sait que $\bar{Z} \sqcup ns_Z^2$. \square

Chapitre 2

Estimation ponctuelle

2.1 Introduction

Considérons toujours un modèle statistique $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), \mathcal{P}^{(n)})$ avec θ le paramètre vectoriel $\in \Theta \subset \mathbb{R}^k$.

Définition 2.1. Soit $g : \Theta \rightarrow \mathbb{R}^k$. Une statistique est appelée *estimateur de $g(\theta)$* lorsqu'elle est à valeurs dans $g(\Theta)$.

Définition 2.2. Soit $\theta \in \Theta \subset \mathbb{R}^k$. Si $g : \Theta \rightarrow \mathbb{R}^m : \theta \mapsto (\theta_{\varphi(1)}, \dots, \theta_{\varphi(m)})$, on appelle les paramètres $\theta_{\varphi(i)}$ les paramètres *d'intérêt*, et on appelle les autres paramètres les paramètres *de nuisance*.

Exemple 2.1. Soient X_1, \dots, X_n iid $\mathcal{N}(\mu, \sigma^2)$. On sait $\theta = (\mu, \sigma^2) \in \Theta = \mathbb{R} \times \mathbb{R}_0^+ \subset \mathbb{R}^2$. Soit $g : \Theta \rightarrow \mathbb{R} : \theta \mapsto \mu$. μ est le paramètre d'intérêt et σ^2 est le paramètre de nuisance.

Remarque. Ne pas connaître le paramètre de nuisance induit une *nuisance* pour déterminer le paramètre d'intérêt.

2.2 Critères d'estimation

Remarque. Afin de définir les estimateurs convergents, il faut définir la notion de convergence, or il n'existe pas une manière canonique de la définir. Il existe donc plusieurs définitions de convergences différentes.

2.2.1 Définitions de convergence

Soient $Z^{(n)} = (Z_1, \dots, Z_n)$ définis pour $n \geq 1$ et sur $(\Omega, \mathcal{F}, \mathbb{P})$.

Définition 2.3. On dit que $Z^{(n)}$ converge *presque sûrement* (ou *stochastiquement*) vers Z lorsque :

$$\mathbb{P} \left[\left\{ \omega \in \Omega \text{ t.q. } Z^{(n)} \xrightarrow[n \rightarrow +\infty]{} Z(\omega) \right\} \right] = 1.$$

Cela se note :

$$Z^{(n)} \xrightarrow[n \rightarrow +\infty]{\text{p.s.}} Z.$$

Définition 2.4. On dit que $Z^{(n)}$ converge *en probabilités* vers Z lorsque :

$$\forall \varepsilon > 0 : \mathbb{P} \left[\left| Z^{(n)} - Z \right| > \varepsilon \right] \xrightarrow[n \rightarrow +\infty]{} 0.$$

Cela se note :

$$Z^{(n)} \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} Z.$$

Définition 2.5. On dit que $Z^{(n)}$ converge en L_r pour $r \in \mathbb{N}^*$ vers Z lorsque :

$$\mathbb{E} \left[\left| Z^{(n)} - Z \right|^r \right] \xrightarrow[n \rightarrow +\infty]{} 0.$$

Cela se note :

$$Z^{(n)} \xrightarrow[n \rightarrow +\infty]{L_r} Z.$$

Remarque. Lorsque $r = 2$, on parle de convergence en moyenne quadratique.

Définition 2.6. On dit que $Z^{(n)}$ converge en loi (ou en distribution) vers Z lorsque :

$$\forall z \text{ point de continuité de } F^Z : F^{Z^{(n)}}(z) \xrightarrow[n \rightarrow +\infty]{} F^Z(z).$$

Cela se note :

$$Z^{(n)} \xrightarrow[n \rightarrow +\infty]{\mathcal{D}} Z.$$

Remarque. Ces définitions sont faites pour des variables aléatoires réelles mais peuvent être étendues à \mathbb{R}^n en appliquant la convergence composante par composante.

2.2.2 Résultats élémentaires sur les convergences

Proposition 2.7. Les convergences sont induites mutuellement par les assertions suivantes :

1. si $Z^{(n)} \xrightarrow[n \rightarrow +\infty]{p.s.} Z$, alors $Z^{(n)} \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} Z$;
2. si $Z^{(n)} \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} Z$, alors $Z^{(n)} \xrightarrow[n \rightarrow +\infty]{\mathcal{D}} Z$;
3. si $Z^{(n)} \xrightarrow[n \rightarrow +\infty]{L_r} Z$, alors $Z^{(n)} \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} Z$.

Théorème 2.8. Les convergences presque sûre, en probabilités, et en loi sont stables par transformations continues.

Théorème 2.9. Notons \rightarrow une convergence soit presque sûre, soit en probabilités. Si $Z^{(n)} \rightarrow Z$, et $Y^{(n)} \rightarrow Y$, alors :

- (i) $Z^{(n)} + Y^{(n)} \rightarrow Z + Y$;
- (ii) $Z^{(n)} \cdot Y^{(n)} \rightarrow Z \cdot Y$;
- (iii) si $\mathbb{P}[Y^{(n)} = 0] = 0$, alors $\frac{Z^{(n)}}{Y^{(n)}} \rightarrow \frac{Z}{Y}$.

Lemme 2.10 (Lemme de Slutsky). Si $Z^{(n)} \xrightarrow[n \rightarrow +\infty]{\mathcal{D}} Z$, et $Y^{(n)} \xrightarrow[n \rightarrow +\infty]{\mathcal{D}} c \neq 0$, alors :

- (i) $Z^{(n)} + Y^{(n)} \xrightarrow[n \rightarrow +\infty]{\mathcal{D}} Z + c$;
- (ii) $Z^{(n)} \cdot Y^{(n)} \xrightarrow[n \rightarrow +\infty]{\mathcal{D}} Z \cdot c$;
- (iii) $\frac{Z^{(n)}}{Y^{(n)}} \xrightarrow[n \rightarrow +\infty]{\mathcal{D}} \frac{Z}{c}$.

Théorème 2.11 (Loi forte des grands nombres). Soient Z_1, Z_2, \dots iid avec $\mathbb{E}[Z_1] < +\infty$. Alors :

$$\bar{Z}^{(n)} = \frac{1}{n} \sum_{k=1}^n Z_k \xrightarrow[n \rightarrow +\infty]{p.s.} \mu = \mathbb{E}[Z_1].$$

Théorème 2.12 (Loi faible des grands nombres). Soient Z_1, Z_2, \dots iid avec $\mathbb{E}[Z_1] < +\infty$. Alors :

$$\bar{Z}^{(n)} = \frac{1}{n} \sum_{k=1}^n Z_k \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} \mu = \mathbb{E}[Z_1].$$

Théorème 2.13 (Théorème central limite (TCL)). Soient Z_1, Z_2, \dots iid, avec $\mathbb{E}[Z_1^2] < +\infty$. Alors :

$$\sqrt{n} \left(Z^{(n)} - \mu \right) \xrightarrow[n \rightarrow +\infty]{\mathcal{D}} W,$$

où :

$$W \sim \mathcal{N}(0, \sigma^2),$$

avec $\sigma^2 = \text{Var}(Z_1)$.

2.2.3 Estimateurs convergents

Définition 2.14. Un estimateur $T^{(n)}(X^{(n)})$ de $g(\theta)$ est dit *faiblement convergent* lorsque :

$$\forall \theta \in \Theta : T^{(n)}(X^{(n)}) \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} g(\theta) \quad \text{sur } \mathbb{P}_\theta^{(n)}.$$

Définition 2.15. Un estimateur $T^{(n)}(X^{(n)})$ de $g(\theta)$ est dit *fortement convergent* lorsque :

$$\forall \theta \in \Theta : T^{(n)}(X^{(n)}) \xrightarrow[n \rightarrow +\infty]{\text{p.s.}} g(\theta) \quad \text{sur } \mathbb{P}_\theta^{(n)}.$$

Exemple 2.2. Soient X_1, \dots, X_n iid $\mathcal{N}(\mu, \sigma^2)$. Prenons $g(\theta) = \mu$ et $T^{(n)}(X^{(n)}) = \bar{X}$. On a bien :

$$T^{(n)}(X^{(n)}) = \bar{X}^{(n)} \xrightarrow[n \rightarrow +\infty]{\text{p.s.}} \mu = \mathbb{E}[X_1] \quad \text{sur } \mathbb{P}_{\mu, \sigma^2}^{(n)}.$$

$T^{(n)}(X^{(n)})$ est donc un estimateur fortement convergent.

Prenons maintenant $T_2^{(n)}(X^{(n)}) = s^2$. On ne peut pas appliquer la loi des grands nombres car les variables aléatoires $(X_i - \bar{X})^2$ sommées ne sont pas indépendantes. On a alors :

$$\begin{aligned} T_2^{(n)}(X^{(n)}) = s^2 &= \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n} \sum_{i=1}^n \left((X_i - \mu)^2 + (\mu - \bar{X})^2 - 2(X_i - \bar{X})(\bar{X} - X_i) \right) \\ &= \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2 - (\bar{X} - \mu)^2, \end{aligned}$$

où $\frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2 \xrightarrow[n \rightarrow +\infty]{\text{p.s.}} \mathbb{E}[(X_i - \mu)^2] = \sigma^2$, par la loi forte des grands nombres, et $(\bar{X} - \mu) \xrightarrow[n \rightarrow +\infty]{\text{p.s.}} 0$.

Donc, par le théorème 2.9, on a $T_2^{(n)}(X^{(n)}) \xrightarrow[n \rightarrow +\infty]{\text{p.s.}} \sigma^2$

Remarque. On a également :

$$\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{n}{n-1} s^2 \xrightarrow[n \rightarrow +\infty]{\text{p.s.}} 1 \cdot \sigma^2.$$

Exemple 2.3. Soient X_1, \dots, X_n iid $\text{Unif}(0, \theta)$, avec $\theta \in \Theta \subset \mathbb{R}$. On veut estimer $g(\theta) = \theta$. L'estimateur $T^{(n)}(X^{(n)}) = \bar{X}$ n'est pas un estimateur convergent car :

$$\bar{X} \xrightarrow[n \rightarrow +\infty]{\text{p.s.}} \mathbb{E}_\theta(X_1) = \frac{\theta}{2} \neq \theta \quad \text{sur } \mathbb{P}_\theta^{(n)}.$$

Par contre, si on prend $T_2^{(n)}(X^{(n)}) = 2\bar{X}$, on a :

$$2\bar{X} \xrightarrow[n \rightarrow +\infty]{\text{p.s.}} 2\mathbb{E}_\theta(X_1) = 2 \cdot \frac{\theta}{2} = \theta \quad \text{sur } \mathbb{P}_\theta^{(n)}.$$

Si on prend $T_3^{(n)}(X^{(n)}) = X_{(n)}$, à savoir l'observation maximale, on a :

$$F_{\theta}^{X^{(n)}}(x) = \begin{cases} 0 & \text{si } x < 0 \\ \frac{x^n}{\theta^n} & \text{si } 0 \leq x \leq \theta \\ 1 & \text{sinon} \end{cases}$$

Posons donc $\varepsilon > 0$. On calcule :

$$\begin{aligned} \mathbb{P}_{\theta}^{(n)} \left[\left| X_{(n)} - \theta \right| > \varepsilon \right] &= \mathbb{P}_{\theta}^{(n)} \left[X_{(n)} \leq \theta - \varepsilon \right] + \mathbb{P}_{\theta}^{(n)} \left[X_{(n)} \geq \theta + \varepsilon \right] = \mathbb{P}_{\theta}^{(n)} \left[X_{(n)} \leq \theta - \varepsilon \right] = F_{\theta}^{X^{(n)}}(\theta - \varepsilon) \\ &= \begin{cases} 0 & \text{si } \varepsilon \geq \theta \\ \left(\frac{\theta - \varepsilon}{\theta} \right)^n & \text{si } 0 < \varepsilon < \theta \end{cases} \longrightarrow 0 \end{aligned}$$

on a alors convergence en probabilité de $X_{(n)}$ vers θ . On en déduit que $T_3^{(n)}(X^{(n)})$ est un estimateur faiblement convergent.

Remarque. L'estimateur $\frac{n+1}{n}X_{(n)}$ est également faiblement convergent.

Remarque. Il n'est pas toujours possible de s'en sortir en invoquant le TCL ou la loi des grands nombres pour déterminer la convergence d'un estimateur. Prenons par exemple X_1, \dots, X_n iid de densité :

$$f^X(x) = \frac{1}{\pi(1 + (x - \theta)^2)}.$$

On a effectivement $\mathbb{E}[X_1] = +\infty$. En réalité :

$$\neg \left(\bar{X}^{(n)} \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} \theta \quad \text{sur } \mathcal{P}_{\theta}^{(n)} \right),$$

mais bien :

$$\bar{X}^{(n)} \xrightarrow[n \rightarrow +\infty]{\mathcal{D}} X_1$$

2.3 Estimateur exhaustif

Définition 2.16. Soit $T^{(n)}(X^{(n)})$, une statistique. On la dit *exhaustive* lorsque :

$$\forall B \in \mathcal{B}(\mathbb{R}^n) : \forall t \in T^{(n)}(\mathbb{R}^n) : \mathbb{P}_{\theta}^{(n)} \left[X^{(n)} \in B \mid T^{(n)}(X^{(n)}) = t \right] \text{ ne dépend pas de } \theta.$$

Remarque. Puisque l'on travaille sur des modèles paramétriques $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), \mathcal{P}^{(n)})$, il existe toujours un $B \in \mathcal{B}(\mathbb{R}^n)$ tel que $\mathbb{P}_{\theta}[X^{(n)} \in B]$ dépende de θ .

Remarque. On peut en comprendre qu'une statistique est exhaustive si la valeur prise par $T^{(n)}(X^{(n)})$ donne toutes les informations contenues par $X^{(n)}$ sur θ .

Exemple 2.4. La statistique identité $x^{(n)} \mapsto x^{(n)}$ est une statistique exhaustive car :

$$\mathbb{P} \left[X^{(n)} \in B \mid X^{(n)} = x^{(n)} \right] = \begin{cases} 1 & \text{si } x^{(n)} \in B \\ 0 & \text{sinon} \end{cases}.$$

Exemple 2.5. Prenons X_1, \dots, X_n iid Bern(p) avec la statistique $T^{(n)}(X^{(n)}) = \sum_{i=1}^n X_i$. Pour évaluer la probabilité :

$$\mathbb{P}_{\mathbf{p}}^{(n)} \left[X^{(n)} \in \{x^{(n)}\} \mid \sum_{i=1}^n X_i = t \right],$$

on est en présence d'une binomiale. Dès lors, si $\sum_{i=1}^n X_i \neq t$, alors la probabilité est nulle. Sinon, la probabilité est $\frac{1}{\binom{n}{t}}$ car il y a $\binom{n}{t}$ moyens d'avoir n observations dont t valant 1 et $n - t$ valant 0. Ces probabilités

ne dépendent donc pas de θ , la statistique $T^{(n)}(X^{(n)}) = \sum_{i=1}^n X_i$ est donc une statistique exhaustive.

Remarque. Si $T^{(n)}(X^{(n)})$ est une statistique bijective, alors elle est exhaustive. Cependant, les estimateurs intéressants sont ceux qui « réduisent » l'information de manière à ce qu'elles soient plus facilement analysables.

Définition 2.17. Soit $X^{(n)} = (X_1, \dots, X_n)$. On appelle la *fonction de vraisemblance de $X^{(n)}$* la fonction :

$$L_{\theta}^{(n)} : \mathbb{R}^n \rightarrow \mathbb{R} : x^{(n)} \mapsto \begin{cases} \mathbb{P}[X^{(n)} = x^{(n)}] & \text{si } X^{(n)} \text{ est de loi discrète} \\ f_{\theta}^{X^{(n)}}(x^{(n)}) & \text{sinon} \end{cases}.$$

Remarque. Dans le cas de variables X_1, \dots, X_n iid, la fonction de vraisemblance correspond toujours à un produit :

$$L_{\theta}^{(n)}(X^{(n)}) = \mathbb{P}[X_1 = x_1, X_2 = x_2, \dots, X_n = x_n] \stackrel{\text{indépendance}}{=} \prod_{i=1}^n \mathbb{P}[X_i = x_i].$$

Théorème 2.18 (Critère de factorisation de Neymann-Fisher). *Dans un modèle paramétrique $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), \mathcal{P}^{(n)})$, une statistique $T^{(n)}(X^{(n)})$ est exhaustive **si et seulement si** pour tout $\theta \in \Theta$, la fonction de vraisemblance $L_{\theta}^{(n)}(X^{(n)})$ est factorisable sous la forme :*

$$L_{\theta}^{(n)}(X^{(n)}) = (g_{\theta} \circ T^{(n)})(X^{(n)})h(X^{(n)}),$$

et ce $\mathbb{P}_{\theta}^{(n)}$ -presque sûrement.

Remarque. Dans cette factorisation, la fonction h ne peut dépendre de θ , et seule la fonction g_{θ} peut en dépendre, mais uniquement par l'intermédiaire de $T^{(n)}$.

Exemple 2.6. En reprenant l'exemple d'au-dessus : X_1, \dots, X_n iid Bern(p) et $T^{(n)}(X^{(n)}) = \sum_{i=1}^n X_i$, on a :

$$L_{\theta}^{(n)}(x^{(n)}) = \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} = p^{\sum_{i=1}^n x_i} (1-p)^{n-\sum_{i=1}^n x_i}.$$

Dès lors, en posant $g_{\theta}(x) = p^x (1-p)^{n-x}$ et $h(x^{(n)}) = 1$, on a bien une factorisation de Neymann-Fisher, ce qui implique que la statistique est exhaustive.

Remarque. Pour chaque statistique exhaustive, il en existe une infinité définies à bijection près. En effet, si $T(X^{(n)})$ est une statistique exhaustive et si H est une fonction bijective quelconque, alors :

$$L_{\theta}^{(n)}(x^{(n)}) = g_{\theta}(T(x^{(n)}))h(x^{(n)}) = (g_{\theta} \circ H^{-1} \circ H \circ T)(x^{(n)})h(x^{(n)}).$$

La fonction $H \circ T$ est donc également une statistique exhaustive.

Remarque. Le critère précédent peut également donner une manière de *deviner* des statistiques exhaustives. Prenons par exemple $X^{(n)} = (X_1, \dots, X_n)$ iid $\mathcal{N}(\mu, \sigma^2)$. Si $\theta = (\mu, \sigma^2) \in \Theta \subset \mathbb{R}^2$, on peut écrire :

$$\begin{aligned} L_{\theta}^{(n)}(x^{(n)}) &= \prod_{i=1}^n f_{\theta}^{X_i}(x_i) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right) = \left(\frac{1}{2\pi\sigma^2}\right)^{\frac{n}{2}} \exp\left(-\sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}\right) \\ &= \left(\frac{1}{2\pi\sigma^2}\right)^{\frac{n}{2}} \exp\left(-\frac{2}{2\sigma^2} \sum_{i=1}^n x_i^2 - \frac{n\mu}{\sigma^2} + \frac{\mu}{\sigma^2} \sum_{i=1}^n x_i\right). \end{aligned}$$

Dès lors, en prenant $T(X^{(n)}) = (\sum_{i=1}^n x_i, \sum_{i=1}^n x_i^2)$, on a bien une statistique exhaustive. Alors, de même, on peut dire que $(\frac{1}{n} \sum_{i=1}^n x_i, \frac{1}{n} \sum_{i=1}^n x_i^2)$ est un estimateur exhaustif (composition avec une bijection).

On peut également dire que $\left(\frac{1}{n} \sum_{i=1}^n x_i, \frac{1}{n} \sum_{i=1}^n x_i^2 - \left(\frac{1}{n} \sum_{i=1}^n x_i\right)^2\right)$ est un estimateur exhaustif (même argument). Or ce dernier vecteur correspond à (\bar{X}, s^2) .

En prenant cette fois $X^{(n)} = (X_1, \dots, X_n)$ iid $\text{Unif}(0, \theta)$, on peut à nouveau construire des statistiques exhaustives :

$$L_{\theta}^{(n)}(x^{(n)}) = \prod_{i=1}^n f_{\theta}^{X_i}(x_i) = \prod_{i=1}^n \frac{1}{\theta} I_{[0 \leq x_i \leq \theta]} = \frac{1}{\theta^n} I_{[0 \leq x_1, \dots, x_n \leq \theta]}.$$

Cela garantit bien que $x^{(n)}$ est une statistique exhaustive. Mais de plus, par commutativité du produit :

$$L_{\theta}^{(n)}(x^{(n)}) = \prod_{i=1}^n f_{\theta}^{X_{(i)}}(x_i) = \frac{1}{\theta^n} I_{[0 \leq x_{(1)}, \dots, x_{(n)} \leq \theta]}.$$

On a donc que la statistique d'ordre est une statistique exhaustive. Or, la condition $0 \leq x_{(1)}, \dots, x_{(n)} \leq \theta$ revient à la condition $0 \leq x_{(1)}, x_{(n)} \leq \theta$. La statistique $(x_{(1)}, x_{(n)})$ est donc également une statistique exhaustive. Pour aller plus loin, décomposant la fonction caractéristique $I_{[0 \leq x_{(1)}, x_{(n)} \leq \theta]}$ en $I_{[0 \leq x_{(1)}]}$ $I_{[x_{(n)} \leq \theta]}$, on peut poser $h(x^{(n)}) = I_{[0 \leq x_{(1)}]}$, ce qui amène à une nouvelle statistique exhaustive : $x^{(n)} \mapsto x_{(n)}$.

À chaque étape du raisonnement, la statistique exhaustive contient *de moins en moins d'information* générale mais conserve l'information sur θ qui est donc en quelque sorte contenue dans $x_{(n)}$.

2.3.1 Estimateurs non biaisés

En se situant toujours dans un modèle statistique $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), \mathcal{P}^{(n)})$, on veut estimer $g(\theta)$, avec $g : \Theta \rightarrow \mathbb{R}^m$.

Définition 2.19. Un estimateur $T^{(n)}(X^{(n)})$ de $g(\theta)$ est dit *non biaisé* lorsque :

$$\forall \theta \in \Theta : \mathbb{E}_{\theta}[T^{(n)}(X^{(n)})] = g(\theta).$$

Définition 2.20. Un estimateur $T^{(n)}(X^{(n)})$ de $g(\theta)$ est dit *asymptotiquement non biaisé* lorsque :

$$\forall \theta \in \Theta : \mathbb{E}_{\theta}[T^{(n)}(X^{(n)})] \xrightarrow{n \rightarrow +\infty} g(\theta).$$

Définition 2.21. Le *biais* d'un estimateur $T^{(n)}(X^{(n)})$ est la quantité :

$$b_{\theta}^{(n)} = b^{(n)}(\theta) = \mathbb{E}_{\theta}[T^{(n)}(X^{(n)})] - g(\theta).$$

Remarque. On remarque donc qu'un estimateur non biaisé a un biais de 0 et qu'un estimateur asymptotiquement non biaisé a un biais qui tend vers 0 pour n tendant vers $+\infty$.

Exemple 2.7. X_1, \dots, X_n iid $\text{Unif}(0, \theta)$, avec $\theta \in \Theta = \mathbb{R}^+ \subset \mathbb{R}$.

— Si $T^{(n)}(X^{(n)}) = 2\bar{X}$, on a :

$$\mathbb{E}_{\theta}^{(n)}[2\bar{X}] = \frac{2}{n} \mathbb{E}_{\theta}^{(n)}\left[\sum_{i=1}^n X_i\right] = \frac{2}{n} \sum_{i=1}^n \mathbb{E}_{\theta}[X_i] = \frac{2}{n} \frac{n\theta}{2} = \theta.$$

— Si $T^{(n)}(X^{(n)}) = X_{(n)}$, on a :

$$\mathbb{E}_{\theta}^{(n)}[X_{(n)}] = \int_{\mathbb{R}} x f_{\theta}^{X_{(n)}}(x) dx = \int_0^{\theta} x \frac{n x^{n-1}}{\theta^n} dx = \frac{n}{\theta^n} \int_0^{\theta} x^n dx = \frac{n}{\theta^n} \left[\frac{x^{n+1}}{n+1} \right]_0^{\theta} = \frac{n}{n+1} \theta.$$

On en déduit que $T^{(n)}(X^{(n)})$ est biaisé car il *voise en moyenne trop à gauche* et a un biais de $-\frac{\theta}{n+1}$. Il est cependant asymptotiquement non biaisé car $\frac{n}{n+1} \xrightarrow{n \rightarrow +\infty} 1$.

Remarque. Si le biais d'un estimateur est négatif, alors c'est que l'estimateur sous-estime en moyenne, alors que si le biais est positif, c'est que l'estimateur surestime.

Remarque. On peut tout de même dire que l'estimateur $\frac{n+1}{n}X_{(n)}$ est non biaisé car :

$$\mathbb{E}_{\theta}^{(n)} \left[\frac{n+1}{n} X_{(n)} \right] = \frac{n+1}{n} \mathbb{E}_{\theta}^{(n)} [X_{(n)}] = \frac{n+1}{n} \frac{n}{n+1} \theta = \theta.$$

Exemple 2.8. Soient X_1, \dots, X_n iid $\mathcal{N}(\mu, \sigma^2)$, avec $\theta = (\mu, \sigma^2)$.

- pour tout $\theta \in \Theta$, on a : $\mathbb{E}_{\theta}[\bar{X}] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}(X_i) = \frac{n\mu}{n} = \mu$. \bar{X} est donc un estimateur sans biais de μ ;
- $\mathbb{E}_{\theta}[s^2] = \mathbb{E}_{\theta}[X_1^2] - \mathbb{E}_{\theta}[\bar{X}^2]$. On remarque que pour toute variable aléatoire Z , on a :

$$\text{Var}(Z) = \mathbb{E}[Z^2] - \mathbb{E}[Z]^2 \iff \mathbb{E}[Z^2] = \text{Var}(Z) + \mathbb{E}[Z]^2.$$

On peut donc remplacer dans la formule de l'espérance de s^2 , et on obtient :

$$\mathbb{E}_{\theta}[s^2] = \text{Var}_{\theta}(X_1) + \mathbb{E}(X_1)^2 - \text{Var}_{\theta}(\bar{X}) - \mathbb{E}(\bar{X})^2.$$

Or on sait $\mathbb{E}_{\theta}(X_1) = \mathbb{E}_{\theta}(\bar{X}) = \mu$. On a donc :

$$\mathbb{E}_{\theta}[s^2] = \text{Var}_{\theta}(X_1) - \text{Var}_{\theta}(\bar{X}) = \sigma^2 - \frac{1}{n^2} \text{Var}_{\theta} \left(\sum_{i=1}^n X_i \right) = \sigma^2 - \frac{1}{n^2} \sum_{i=1}^n \text{Var}_{\theta}(X_i) = \sigma^2 - \frac{n\sigma^2}{n^2} = \frac{n-1}{n} \sigma^2.$$

On en conclut que l'estimateur s^2 est biaisé pour σ^2 et de biais $\frac{-\sigma^2}{n} \xrightarrow{n \rightarrow +\infty} 0$.

Notons alors $S^2 := \frac{n}{n-1} s^2$. On a que $\mathbb{E}_{\theta}[S^2] = \sigma^2$, et donc S^2 est un estimateur sans biais.

Remarque. Le non biais est une propriété fragile. Soient X_1, \dots, X_n iid $\mathcal{N}(\mu, \sigma^2)$ où l'on veut estimer $g(\theta) = \sigma$ (et pas σ^2).

Que vaut $\mathbb{E}_{\theta}[S]$? On sait $\text{Var}_{\theta}(S) = \mathbb{E}_{\theta}[S^2] - \mathbb{E}_{\theta}[S]^2 = \sigma^2 - \mathbb{E}_{\theta}[S]^2$. Or $\text{Var}_{\theta}(S) \geq 0$, et donc $\sigma^2 \geq \mathbb{E}_{\theta}[S]^2$. On en déduit $\mathbb{E}_{\theta}[S] \leq \sigma$.

Remarque. De plus, il n'existe pas toujours d'estimateur sans biais. Soit $X_1 \sim \text{Bern}(p)$. On veut estimer $g(p) = p^2 \in [0, 1]$. L'estimateur $T(X^{(n)})$ est entièrement déterminé par $T(0)$ et $T(1)$. Imposons donc pour tout $p \in [0, 1] : \mathbb{E}_{\theta}[T(X_1)] = p^2$. On a donc :

$$p^2 = \mathbb{E}_{\theta}[T(X_1)] = T(0)\mathbb{P}[X_1 = 0] + T(1)\mathbb{P}[X_1 = 1] = T(0)(1-p) + T(1)p.$$

En réarrangeant cette équation du second degré, on obtient :

$$\forall p \in [0, 1] : p^2 + (T(0) - T(1))p - T(0) = 0.$$

Or une telle équation ne peut avoir que 2 racines tout au plus, et ici, une infinité non-dénombrable est requise. Il n'existe donc pas de telle fonction T , et donc par extension, il n'existe pas d'estimateur sans biais de p^2 .

Exemple 2.9. Prenons X_1, \dots, X_n iid $\mathcal{N}(\mu, 1)$, $g(\theta) = g(\mu) = \mu$. Prenons $T^{(n)}(X^{(n)}) = \overline{X^{(n)}} + Y$, où $Y = \pm 10^9$, avec probabilité $\frac{1}{2}$ pour chaque. On a alors :

$$\mathbb{E}_{\mu}[T^{(n)}(X^{(n)})] = \mathbb{E}_{\mu}[\overline{X^{(n)}}] + \mathbb{E}_{\mu}[Y] = \mu + 0 = \mu.$$

L'estimateur $T^{(n)}(X^{(n)})$ est donc sans biais, mais est très mauvais : sur-/sous-estime toujours à $\simeq 10^9$ près.

2.3.2 Estimateurs à dispersion minimale

Définition 2.22. L'erreur quadratique moyenne d'un estimateur $T^{(n)}(X^{(n)})$ de $g(\theta)$ ($\in \mathbb{R}$) est la quantité :

$$\text{MSE}_{\theta}[T^{(n)}(X^{(n)})] := \mathbb{E}_{\theta} \left[\left| T^{(n)}(X^{(n)}) - g(\theta) \right|^2 \right].$$

Définition 2.23. On appelle l'erreur absolue moyenne la quantité :

$$\text{MAE}_\theta[T^{(n)}(X^{(n)})] = \mathbb{E}_\theta \left[\left| T^{(n)}(X^{(n)}) - g(\theta) \right| \right]$$

Remarque.

$$\begin{aligned} \text{MSE}_\theta[T^{(n)}(X^{(n)})] &= \mathbb{E}_\theta \left[\left| T^{(n)}(X^{(n)}) - g(\theta) \right|^2 \right] = \text{Var}_\theta \left[T^{(n)}(X^{(n)}) - g(\theta) \right] - \mathbb{E}_\theta \left[T^{(n)}(X^{(n)}) - g(\theta) \right]^2 \\ &= \text{Var}_\theta[T^{(n)}(X^{(n)})] - b_\theta^{(n)}(T^{(n)}(X^{(n)}))^2. \end{aligned}$$

Puisque $\text{Var}_\theta(T^{(n)}(X^{(n)})) \geq 0$ et $b_\theta^{(n)}(T^{(n)}(X^{(n)})) \geq 0$, pour avoir $\text{MSE}[T^{(n)}(X^{(n)})] \xrightarrow[n \rightarrow +\infty]{} 0$, il faut :

$$\begin{cases} \text{Var}_\theta(T^{(n)}(X^{(n)})) \xrightarrow[n \rightarrow +\infty]{} 0, \\ b_\theta^{(n)}(T^{(n)}(X^{(n)})) \xrightarrow[n \rightarrow +\infty]{} 0. \end{cases}$$

Cela dit que sous $\mathbb{P}_\theta^{(n)}$, on a $T^{(n)}(X^{(n)}) \xrightarrow{L^2} g(\theta)$ (et également $T^{(n)}(X^{(n)}) \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} g(\theta)$).

On peut également dire que si $\text{MSE}_\theta[T^{(n)}(X^{(n)})] \rightarrow 0$, alors $T^{(n)}(X^{(n)})$ est un estimateur faiblement convergent.

Remarque. Le MSE sert d'« arbitrage » entre la variance et le biais. Cet arbitrage est bien souvent nécessaire car il arrive fréquemment que baisser le biais (respectivement la variance) augmente la variance (respectivement le biais).

Exemple 2.10. X_1, \dots, X_n iid $\text{Unif}(0, \theta)$. Prenons $\theta \in \Theta = \mathbb{R}_0^+ \subset \mathbb{R}$. Prenons $T_1^{(n)}(X^{(n)}) = X_{(n)}$. On sait que :

$$\mathbb{E}_\theta[T_1^{(n)}(X^{(n)})] = \frac{n}{n+1}\theta,$$

ce qui nous permet de calculer la variance :

$$\text{Var}_\theta(X_{(n)}) = \mathbb{E}_\theta(X_{(n)}^2) - \mathbb{E}_\theta(X_{(n)})^2,$$

où :

$$\mathbb{E}_\theta(X_{(n)}^2) = \int_{\mathbb{R}} x^2 f^{X_{(n)}}(x) dx = \int_0^\theta x^2 \frac{nx^{n-1}}{\theta^n} dx = \frac{n}{\theta^n} \int_0^\theta x^{n+1} dx = \frac{n}{\theta^n} \left[\frac{x^{n+2}}{n+2} \right]_0^\theta = \frac{n\theta^2}{n+2}.$$

On trouve finalement la variance donnée par :

$$\frac{n\theta^2}{n+2} - \frac{n^2\theta^2}{(n+1)^2} = n\theta^2 \left(\frac{(n+1)^2 - n(n+2)}{(n+2)(n+1)^2} \right) = \frac{n\theta^2}{(n+2)(n+1)^2}.$$

On trouve finalement une erreur quadratique moyenne de :

$$\text{MSE}_\theta[T_1^{(n)}(X^{(n)})] = \frac{2\theta^2}{(n+1)(n+2)} \xrightarrow[n \rightarrow +\infty]{} 0.$$

En prenant $T_2^{(n)}(X^{(n)}) = \frac{n+1}{n}X_{(n)}$, on annule le biais, mais on augmente la variance :

$$\text{Var}_\theta[T_2^{(n)}(X^{(n)})] = \left(\frac{n+1}{n} \right)^2 \text{Var}_\theta[X_{(n)}] = \frac{\theta^2}{n(n+2)}.$$

On trouve alors :

$$\forall \theta \in \Theta : \text{MSE}_\theta[T_2^{(n)}(X^{(n)})] = \frac{\theta^2}{n(n+2)} \leq \text{MSE}_\theta[T_1^{(n)}(X^{(n)})].$$

Dans le cas présent, annuler le biais donne une erreur quadratique moyenne plus faible. Donc ici, la variance a « moins augmenté que le biais n'a diminué ».

Exemple 2.11. Prenons maintenant X_1, \dots, X_n iid $\mathcal{N}(\mu, \sigma^2)$ et $g(\theta) = \sigma^2$.

Pour $T_1^{(n)}(X^{(n)}) = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$, on trouve :

$$\text{MSE}_\theta[T_1^{(n)}(X^{(n)})] = \frac{2(n-1)\sigma^4}{n^2}.$$

À nouveau, il existe un estimateur sans-biais :

$$T_2^{(n)}(X^{(n)}) = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{n-1}{n} T_1^{(n)}(X^{(n)}).$$

Dans ce cas, on trouve :

$$\forall \theta \in \Theta : \text{MSE}_\theta[T_2^{(n)}(X^{(n)})] = \frac{2\sigma^4}{n-1} \geq \text{MSE}_\theta[T_1^{(n)}(X^{(n)})].$$

Remarque. Dans les deux exemples ci-dessus, l'inégalité est stricte pour $n \geq 2$.

De plus, l'inégalité tient pour tout $\theta \in \Theta$. Cela permet de définir qu'un estimateur est meilleur que l'autre. Avoir deux estimateurs tels que l'erreur quadratique moyenne de l'un est meilleure que l'autre pour certaines valeurs de $g(\theta)$, et inversement pour d'autres ne permet pas de dire que l'un est meilleur que l'autre car la véritable valeur de $g(\theta)$ n'est pas connue. On ne peut donc pas savoir quel estimateur choisir.

Définition 2.24. Soit \mathcal{C} , une classe d'estimateurs de $g(\theta)$. On dit que $T_*^{(n)}$ est à erreur quadratique moyenne minimale dans \mathcal{C} lorsque :

- $T_*^{(n)} \in \mathcal{C}$;
- $\forall T^{(n)} \in \mathcal{C} : \forall \theta \in \Theta : \text{MSE}_\theta[T_*^{(n)}] \leq \text{MSE}_\theta[T^{(n)}]$.

Remarque. On peut prendre $\mathcal{C} = \{T^{(n)} \text{ t.q. } \mathbb{E}_\theta[T^{(n)2}] < +\infty\}$, mais on n'en prend qu'un sous-ensemble strict bien souvent car dans un tel \mathcal{C} , on peut prendre $T_{\theta_0}^{(n)}$, pour un certain $\theta_0 \in \Theta$ défini par $T_{\theta_0}^{(n)}(X^{(n)}) = g(\theta_0)$. On trouve donc :

$$\text{MSE}_\theta[T_{\theta_0}^{(n)}(X^{(n)})] = \mathbb{E}_\theta[(g(\theta_0) - g(\theta))^2] = (g(\theta_0) - g(\theta))^2.$$

La fonction d'erreur quadratique moyenne est donc une parabole qui s'annule en $\theta_0 = \theta$. Pour avoir un tel $T_*^{(n)}$, il faut que $\text{MSE}_{\theta_0}[T_*^{(n)}] \leq \text{MSE}_{\theta_0}[T_{\theta_0}^{(n)}] = 0$. Et ce, pour tout $\theta_0 \in \Theta$. Il faut donc avoir :

$$\forall \theta \in \Theta : T_*^{(n)} = g(\theta) \quad \text{sous } \mathbb{P}_\theta^{(n)}.$$

Pour résoudre ce problème, il faut donc réduire \mathcal{C} afin de ne plus avoir de tels estimateurs *pathologiques*.

Définition 2.25. Soit $Z = (Z_1, \dots, Z_m)^T$, un vecteur aléatoire (vecteur de variables aléatoires). On définit :

$$\mathbb{E}_\theta(Z) := (\mathbb{E}_\theta[Z_1], \dots, \mathbb{E}_\theta[Z_m])^T.$$

On définit également :

$$\text{Var}_\theta[Z] = \mathbb{E} \left[(Z - \mathbb{E}_\theta[Z])(Z - \mathbb{E}_\theta[Z])^T \right] \in \mathbb{R}^{m \times m}.$$

Remarque. On observe que :

$$\text{Var}_\theta[Z]_{ij} = \mathbb{E}_\theta \left[(Z - \mathbb{E}_\theta[Z])_i (Z - \mathbb{E}_\theta[Z])_j^T \right] = \mathbb{E}_\theta \left[(Z_i - \mathbb{E}_\theta[Z_i]) (Z_j - \mathbb{E}_\theta[Z_j]) \right] = \text{Cov}[Z_i, Z_j].$$

Cela veut dire :

$$\text{Var}_\theta[Z] = \begin{pmatrix} \text{Var}_\theta[Z_1] & \text{Cov}[Z_1, Z_2] & \dots & \text{Cov}[Z_1, Z_n] \\ \text{Cov}[Z_2, Z_1] & \text{Var}_\theta[Z_2] & \ddots & \text{Cov}[Z_2, Z_n] \\ \vdots & & \ddots & \vdots \\ \text{Cov}[Z_n, Z_1] & \dots & \dots & \text{Var}_\theta[Z_n] \end{pmatrix}$$

On appelle cette matrice la *matrice de variance/covariance* (pour des raisons évidentes). On voit donc que cette matrice est symétrique car $\text{Cov}[Z_i, Z_j] = \text{Cov}[Z_j, Z_i]$.

Définition 2.26. Soit A une matrice. On dit que $A \geq 0$ si la forme bilinéaire associée est semi-définie positive.

Proposition 2.27. Soit Z un vecteur aléatoire, et soient $A \in \mathbb{R}^{k \times m}$, $b \in \mathbb{R}^k$. Alors :

- $\mathbb{E}_\theta[AZ + b] = A\mathbb{E}_\theta[Z] + b$;
- $\text{Var}_\theta[AZ + b] = A \text{Var}_\theta[Z] A^T$;
- $\text{Var}_\theta[Z] \geq 0$.

Démonstration.

- On observe que $\mathbb{E}_\theta[AZ + b] = (\mathbb{E}_\theta[(AZ)_i + b_i])_i$, où :

$$\begin{aligned} \mathbb{E}_\theta[(AZ)_i + b_i] &= \mathbb{E}_\theta[(AZ)_i] + b_i = \mathbb{E}_\theta \left[\sum_{j=1}^k A_{ij} Z_j \right] + b_i = \sum_{j=1}^k \mathbb{E}_\theta[A_{ij} Z_j] + b_i \\ &= \sum_{j=1}^k A_{ij} \mathbb{E}_\theta[Z_j] + b_i = \sum_{j=1}^k A_{ij} (\mathbb{E}_\theta[Z])_j + b_i = (A\mathbb{E}_\theta[Z] + b)_i. \end{aligned}$$

- On remarque premièrement que $\text{Var}_\theta(AZ + b) = \mathbb{E}_\theta \left[(AZ + b - A\mathbb{E}_\theta(Z) - b)(AZ + b - A\mathbb{E}_\theta(Z) - b)^T \right] = \mathbb{E}_\theta \left[(AZ - A\mathbb{E}_\theta(Z))(AZ - A\mathbb{E}_\theta(Z))^T \right] = \text{Var}_\theta[AZ]$. De là, on trouve :

$$\begin{aligned} \text{Var}_\theta[AZ]_{ij} &= \mathbb{E}_\theta \left[(AZ - A\mathbb{E}_\theta(Z))_i (AZ - A\mathbb{E}_\theta(Z))_j \right] = \mathbb{E}_\theta \left[((AZ)_i - \mathbb{E}_\theta((AZ)_i))((AZ)_j - \mathbb{E}_\theta((AZ)_j)) \right] \\ &= \mathbb{E}_\theta[(AZ)_i (AZ)_j] - \mathbb{E}_\theta[(AZ)_i] \mathbb{E}_\theta[(AZ)_j] \\ &= \mathbb{E}_\theta \left[\left(\sum_{\delta=1}^m A_{i\delta} Z_\delta \right) \left(\sum_{\gamma=1}^m A_{j\gamma} Z_\gamma \right) \right] - \mathbb{E}_\theta \left[\sum_{\delta=1}^m A_{i\delta} Z_\delta \right] \mathbb{E}_\theta \left[\sum_{\gamma=1}^m A_{j\gamma} Z_\gamma \right] \\ &= \sum_{\delta=1}^m \sum_{\gamma=1}^m A_{i\delta} A_{j\gamma} \mathbb{E}_\theta[Z_\delta Z_\gamma] - \sum_{\delta=1}^m \sum_{\gamma=1}^m A_{i\delta} A_{j\gamma} \mathbb{E}_\theta[Z_\delta] \mathbb{E}_\theta[Z_\gamma] \\ &= \sum_{\delta=1}^m \sum_{\gamma=1}^m A_{i\delta} A_{j\gamma} (\mathbb{E}_\theta[Z_\delta Z_\gamma] - \mathbb{E}_\theta[Z_\delta] \mathbb{E}_\theta[Z_\gamma]) \\ &= \sum_{\delta=1}^m \sum_{\gamma=1}^m A_{i\delta} A_{j\gamma} \text{Var}_\theta[Z]_{\delta\gamma} \\ &= \sum_{\delta=1}^m \sum_{\gamma=1}^m A_{i\delta} \text{Var}_\theta[Z]_{\delta\gamma} (A^T)_{\gamma j} \\ &= \left(A \text{Var}_\theta[Z] A^T \right)_{ij} \end{aligned}$$

— soit $v \in \mathbb{R}^m$. On remarque que $v^T \text{Var}_\theta[Z]v = \text{Var}_\theta[v^T Z] \geq 0$.

□

Définition 2.28. Soient $Z = (Z_1, \dots, Z_m)^T$, et $Y = (Y_1, \dots, Y_\ell)^T$. On définit la covariance de Y et Z par :

$$\text{Cov}[Y, Z] := \mathbb{E}_\theta [(Y - \mathbb{E}_\theta[Y])(Z - \mathbb{E}_\theta[Z])] .$$

Proposition 2.29. Soient $Z = (Z_1, \dots, Z_m)^T$, et $Y = (Y_1, \dots, Y_\ell)^T$. Alors :

- $\text{Cov}[Y, Z]_{ij} = \text{Cov}[Y_i, Z_j]$;
- $\text{Cov}[Z, Y] = \text{Cov}[Y, Z]^T$;
- $\text{Cov}[Z, Z] = \text{Var}_\theta[Z]$;
- $\text{Cov}[AY + b, CZ + d] = A \text{Cov}[Y, Z] C^T$

Définition 2.30. Soient $g(\theta) \in \mathbb{R}^m$ et $T^{(n)}(X^{(n)})$, un estimateur de $g(\theta)$. On définit :

$$\text{MSE}_\theta[T^{(n)}(X^{(n)})] := \mathbb{E}_\theta \left[(T^{(n)}(X^{(n)}) - g(\theta))(T^{(n)}(X^{(n)}) - g(\theta))^T \right] \in \text{Mat}(m, m).$$

Remarque. $\text{MSE}_\theta[T^{(n)}(X^{(n)})] = \mathbb{E}_\theta \left[\left(T_i^{(n)}(X^{(n)}) - g(\theta) \right) \left(T_j^{(n)}(X^{(n)}) - g(\theta) \right)^T \right]$. En particulier :

$$\text{MSE}_\theta[T^{(n)}(X^{(n)})]_{ii} = \text{MSE}_\theta[T_i^{(n)}].$$

Définition 2.31. Soient $A, B \in \text{Mat}(m, m)$. On dit que $A \geq B$ lorsque $A - B \geq 0$, c-à-d lorsque la forme bilinéaire définie par $(A - B)$ est semi définie positive.

Définition 2.32. Soit \mathcal{C} , une classe d'estimateurs de $g(\theta)$. Alors $T_*^{(n)}$ est à erreur quadratique moyenne minimale dans \mathcal{C} lorsque :

- (i) $T_*^{(n)} \in \mathcal{C}$;
- (ii) $\forall T^{(n)} \in \mathcal{C} : \forall \theta \in \Theta : \text{MSE}_\theta[T^{(n)}] \geq \text{MSE}_\theta[T_*^{(n)}]$.

Proposition 2.33. Pour tout $\theta \in \Theta$, $T^{(n)} \in \mathcal{C}$, on a :

$$\text{MSE}_\theta[T^{(n)}] \geq 0.$$

Démonstration. Soit $v \in \mathbb{R}^m$. On trouve :

$$\begin{aligned} v^T \text{MSE}_\theta[T^{(n)}]v &= v^T \mathbb{E}_\theta \left[(T^{(n)} - g(\theta)) (T^{(n)} - g(\theta))^T \right] v = \mathbb{E}_\theta \left[v^T (T^{(n)} - g(\theta)) (T^{(n)} - g(\theta))^T v \right] \\ &= \mathbb{E}_\theta \left[\left(v^T (T^{(n)} - g(\theta)) \right) \left(v^T (T^{(n)} - g(\theta)) \right)^T \right] \\ &= \mathbb{E}_\theta \left[\left(v^T (T^{(n)} - g(\theta)) \right)^2 \right] \geq 0. \end{aligned}$$

□

Proposition 2.34. Soient $T_1^{(n)}, T_2^{(n)}$, deux estimateurs de $g(\theta)$ tels que :

$$\text{MSE}_\theta[T_1^{(n)}] \geq \text{MSE}_\theta[T_2^{(n)}].$$

Alors :

$$\forall v \in \mathbb{R}^m : \text{MSE}_\theta[v^T T_1^{(n)}] \geq \text{MSE}_\theta[v^T T_2^{(n)}].$$

Démonstration.

$$\begin{aligned}
\text{MSE}_\theta[\mathbf{v}^T \mathbf{T}_1^{(n)}] - \text{MSE}_\theta[\mathbf{v}^T \mathbf{T}_2^{(n)}] &= \mathbb{E}_\theta \left[\left(\mathbf{v}^T \mathbf{T}_1^{(n)} - \mathbf{v}^T \mathbf{g}(\theta) \right)^2 \right] - \mathbb{E}_\theta \left[\left(\mathbf{v}^T \mathbf{T}_2^{(n)} - \mathbf{v}^T \mathbf{g}(\theta) \right)^2 \right] \\
&= \mathbb{E}_\theta \left[\mathbf{v}^T \left(\mathbf{T}_1^{(n)} - \mathbf{g}(\theta) \right) \right] - \mathbb{E}_\theta \left[\mathbf{v}^T \left(\mathbf{T}_2^{(n)} - \mathbf{g}(\theta) \right) \right] \\
&= \mathbf{v}^T \text{MSE}_\theta[\mathbf{T}_1^{(n)}] \mathbf{v} - \mathbf{v}^T \text{MSE}_\theta[\mathbf{T}_2^{(n)}] \mathbf{v} = \mathbf{v}^T \left(\text{MSE}_\theta[\mathbf{T}_1^{(n)}] - \text{MSE}_\theta[\mathbf{T}_2^{(n)}] \right) \mathbf{v} \geq 0,
\end{aligned}$$

par définition de semi-positivité. \square

2.3.3 Estimateurs efficaces

Définition 2.35. On note l'ensemble des valeurs $\mathbf{x}^{(n)}$ de \mathbb{R}^n prises par $\mathbf{X}^{(n)}$ avec probabilité non-nulle par l'ensemble :

$$\mathcal{X}^{(n)} := \{\mathbf{x}^{(n)} \in \mathbb{R}^n \text{ t.q. } L_\theta^{(n)}(\mathbf{x}^{(n)}) > 0\}.$$

Définition 2.36. Soit un modèle statistique. On définit la *matrice d'information de Fisher* par :

$$I^{(n)}(\theta) := \int_{\mathcal{X}^{(n)}} \left[\nabla_\theta \ln L_\theta^{(n)}(\mathbf{x}^{(n)}) \right] \left[\nabla_\theta \ln L_\theta^{(n)}(\mathbf{x}^{(n)}) \right]^T L_\theta^{(n)}(\mathbf{x}^{(n)}) d\mathbf{x}^{(n)}.$$

Définition 2.37. Soit $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), \mathcal{P}^{(n)})$, un modèle statistique. On le dit *régulier* lorsque :

- H1 Θ est ouvert ;
- H2 $\mathcal{X}^{(n)}$ ne dépend pas de θ ;
- H3 $\forall \mathbf{x}^{(n)} \in \mathcal{X}^{(n)} : \theta \mapsto L_\theta^{(n)}(\mathbf{x}^{(n)})$ est différentiable sur θ ;
- H4 l'expression $\int_{\mathcal{X}^{(n)}} L_\theta^{(n)}(\mathbf{x}^{(n)}) d\mathbf{x}^{(n)}$ est différentiable sous le signe ;
- H5 $\forall \theta \in \Theta : I^{(n)}(\theta)$ existe, est finie, et est inversible.

Remarque. Les intégrales doivent être comprises comme des sommes (voire des séries dans le cas infini) dans les cas discrets.

Remarque. Un artifice fréquemment utilisé ici est le suivant :

$$\frac{\partial}{\partial \theta_i} L_\theta^{(n)}(\mathbf{x}^{(n)}) = \frac{\partial}{\partial \theta_i} L_\theta^{(n)}(\mathbf{x}^{(n)}) \frac{L_\theta^{(n)}(\mathbf{x}^{(n)})}{L_\theta^{(n)}(\mathbf{x}^{(n)})} = \frac{\partial}{\partial \theta_i} \ln L_\theta^{(n)}(\mathbf{x}^{(n)}) L_\theta^{(n)}(\mathbf{x}^{(n)}).$$

Proposition 2.38. Dans un modèle statistique régulier, on a :

$$\mathbb{E}_\theta \left[\nabla_\theta \ln L_\theta^{(n)}(\mathbf{x}^{(n)}) \right] = 0.$$

Démonstration. Par définition de l'espérance :

$$\mathbb{E}_\theta \left[\nabla_\theta \ln L_\theta^{(n)}(\mathbf{x}^{(n)}) \right] = \int_{\mathcal{X}^{(n)}} \left(\nabla_\theta \ln L_\theta^{(n)}(\mathbf{x}^{(n)}) \right) L_\theta^{(n)}(\mathbf{x}^{(n)}) d\mathbf{x}^{(n)} = \int_{\mathcal{X}^{(n)}} \nabla_\theta L_\theta^{(n)}(\mathbf{x}^{(n)}) d\mathbf{x}^{(n)}.$$

Par hypothèse de régularité, on sait :

$$\int_{\mathcal{X}^{(n)}} \nabla_\theta L_\theta^{(n)}(\mathbf{x}^{(n)}) d\mathbf{x}^{(n)} = \nabla_\theta \int_{\mathcal{X}^{(n)}} L_\theta^{(n)}(\mathbf{x}^{(n)}) d\mathbf{x}^{(n)}.$$

On trouve finalement :

$$\mathbb{E}_\theta \left[\nabla_\theta \ln L_\theta^{(n)}(\mathbf{x}^{(n)}) \right] = \nabla_\theta \int_{\mathcal{X}^{(n)}} L_\theta^{(n)}(\mathbf{x}^{(n)}) d\mathbf{x}^{(n)} = \nabla_\theta 1 = 0.$$

\square

Remarque. Par la proposition précédente, on peut dire :

$$I^{(n)}(\theta) = \mathbb{E}_\theta \left[\left[\nabla_\theta \ln L_\theta^{(n)}(X^{(n)}) \right] \left[\nabla_\theta \ln L_\theta^{(n)}(X^{(n)}) \right]^T \right] = \text{Var}_\theta \left[\nabla_\theta \ln L_\theta^{(n)}(X^{(n)}) \right].$$

Proposition 2.39. Dans un modèle d'échantillonnage, on a :

$$I^{(n)}(\theta) = nI^{(1)}(\theta).$$

Démonstration. Les variables X_1, \dots, X_n étant iid (modèle d'échantillonnage), on peut exprimer :

$$\begin{aligned} I^{(n)}(\theta) &= \text{Var}_\theta \left[\nabla_\theta \ln L_\theta^{(n)}(X^{(n)}) \right] = \text{Var}_\theta \left[\nabla_\theta \ln \left(\prod_{i=1}^n L_\theta^{(1)}(X_i) \right) \right] \\ &= \text{Var}_\theta \left[\sum_{i=1}^n \nabla_\theta \ln L_\theta^{(1)}(X_i) \right] = \sum_{i=1}^n \text{Var}_\theta \left[\nabla_\theta \ln L_\theta^{(1)}(X_i) \right] \\ &= n \text{Var}_\theta \left[\nabla_\theta \ln L_\theta^{(1)}(X_1) \right] = nI^{(1)}(\theta). \end{aligned}$$

□

Remarque. On en déduit que n variables aléatoires iid contiennent n fois plus d'information qu'une seule d'entre elles.

Remarque. pour comprendre l'importance de l'hypothèse H5, supposons $k = 1$ et $\forall \theta \in \Theta : I^{(n)}(\theta) = 0$. 0 n'est pas inversible, ce qui viole H5. Alors par l'égalité d'une remarque précédente :

$$\text{Var}_\theta \left[\frac{d}{d\theta} \ln L_\theta^{(n)}(X^{(n)}) \right] = 0.$$

On en déduit que $\frac{d}{d\theta} \ln L_\theta^{(n)}(X^{(n)}) = 0$, et donc que $\ln L_\theta^{(n)}(X^{(n)})$ est constante sur son espérance, c-à-d 0. On en déduit :

$$\frac{d}{d\theta} L_\theta^{(n)}(X^{(n)}) = 0 \quad \forall \theta \in \Theta \quad \mathbb{P}_\theta - \text{p.s.}$$

Et donc, pour tout $\theta \in \Theta$, on a :

$$\mathbb{P}[X^{(n)} \in B] = \int_B L_\theta^{(n)} dx^{(n)},$$

et en dérivant les deux membres de l'égalité :

$$\frac{d}{d\theta} \mathbb{P}[X^{(n)} \in B] = \int_B \frac{d}{d\theta} L_\theta^{(n)}(x^{(n)}) dx^{(n)}.$$

Cela veut dire que la probabilité $\mathbb{P}[X^{(n)} \in B]$ est constante pour toutes valeurs de θ . Les \mathbb{P}_θ ne sont donc plus différenciables. On a donc perdu toute information sur θ .

Définition 2.40. Dans un modèle statistique régulier, un estimateur $T^{(n)}(X^{(n)})$ de $g(\theta)$ est dit *régulier* lorsque :

- (i) $\forall \theta \in \Theta : \mathbb{E}_\theta \left[\left\| T^{(n)}(X^{(n)}) \right\|^2 \right] < +\infty$;
- (ii) $\psi_\theta := \mathbb{E}_\theta[T^{(n)}(X^{(n)})] = \int_{\mathcal{X}^{(n)}} T^{(n)}(x^{(n)}) L_\theta^{(n)}(x^{(n)}) dx^{(n)}$ est différentiable sous le signe pour tout $\theta \in \Theta$.

Théorème 2.41. Soient un modèle statistique régulier, et $T^{(n)}(X^{(n)})$ un estimateur régulier de $g(\theta)$. Alors :

$$\forall \theta \in \Theta : \text{MSE}_\theta(T^{(n)}(X^{(n)})) = \mathbb{E}_\theta \left[\left[T^{(n)}(X^{(n)}) - g(\theta) \right] \left[T^{(n)}(X^{(n)}) - g(\theta) \right]^T \right] \geq \Delta_\theta I^{(n)}(\theta)^{-1} \Delta_\theta^T,$$

où $\Delta_\theta = \text{Jac } \psi = \left[\frac{\partial \psi_i}{\partial \theta_j}(\theta) \right] \in \text{Mat}(m, k)$.

Remarque. Dans le cas où $g(\theta) = \theta = \psi(\theta)$, on a un estimateur non-biaisé, et donc :

$$\text{Jac } \psi = \text{Jac Id} = \text{Id}.$$

Et donc, on a :

$$\forall \theta \in \Theta : \text{MSE}_\theta(T^{(n)}(X^{(n)})) \geq I^{(n)}(\theta)^{-1}.$$

Remarque. Dans le cas d'un modèle d'échantillonnage, on a $(I^{(n)})^{-1} = n^{-1}I^{(4)}(\theta)^{-1}$, et donc :

$$\forall \theta \in \Theta : \text{MSE}_\theta(T^{(n)}(X^{(n)})) \geq n^{-1} \Delta_\theta I^{(1)}(\theta)^{-1} \Delta_\theta^T \xrightarrow{n \rightarrow +\infty} 0.$$

Preuve du Théorème 2.41. Notons d'abord :

$$\begin{aligned} (\Delta_\theta)_{ij} &= \frac{\partial \psi_i}{\partial \theta_j}(\theta) = \frac{\partial}{\partial \theta_j} \mathbb{E}_\theta [T_i^{(n)}(X^{(n)})] = \frac{\partial}{\partial \theta_j} \int_{\mathcal{X}^{(n)}} T_i^{(n)}(x^{(n)}) L_\theta^{(n)} dx^{(n)} \\ &= \int_{\mathcal{X}^{(n)}} T_i(x^{(n)}) \frac{\partial}{\partial \theta_j} L_\theta^{(n)}(x^{(n)}) dx^{(n)} = \int_{\mathcal{X}^{(n)}} T_i(x^{(n)}) \frac{\partial}{\partial \theta_j} \ln L_\theta^{(n)}(x^{(n)}) L_\theta^{(n)}(x^{(n)}) dx^{(n)}. \end{aligned}$$

On a donc une espérance donnée par :

$$(\Delta_\theta)_{ij} = \mathbb{E}_\theta \left[T_i(X^{(n)}) \frac{\partial}{\partial \theta_j} \ln L_\theta^{(n)}(X^{(n)}) \right] = \mathbb{E}_\theta \left[T^{(n)}(X^{(n)}) \nabla_\theta \ln L_\theta^{(n)}(X^{(n)}) \right]_{ij}.$$

On a alors l'égalité suivante :

$$\Delta_\theta = \mathbb{E}_\theta \left[T^{(n)}(X^{(n)}) \nabla_\theta \ln L_\theta^{(n)}(X^{(n)}) \right].$$

On veut ensuite montrer :

$$\begin{aligned} \text{MSE}_\theta[T^{(n)}] &= \mathbb{E}_\theta \left[\left(T^{(n)} - g(\theta) \right) \left(T^{(n)} - g(\theta) \right)^T \right] \stackrel{(1)}{=} \text{Var}[T^{(n)}] + (\psi(\theta) - g(\theta)) (\psi(\theta) - g(\theta))^T \\ &\stackrel{(2)}{\geq} \text{Var}_\theta[T^{(n)}] \\ &\stackrel{(3)}{\geq} \Delta_\theta I^{(n)}(\theta)^{-1} \Delta_\theta^T \end{aligned}$$

Montrons d'abord (1). Pour cela :

$$\begin{aligned} \text{MSE}_\theta(T^{(n)}) &= \mathbb{E}_\theta \left[\left((T^{(n)} - \psi(\theta)) + (\psi(\theta) - g(\theta)) \right) \left((T^{(n)} - \psi(\theta)) + (\psi(\theta) - g(\theta)) \right)^T \right] \\ &= \mathbb{E}_\theta[(T^{(n)} - \psi(\theta))(T^{(n)} - \psi(\theta))^T] + \mathbb{E}_\theta[(T^{(n)} - \psi(\theta))(\psi(\theta) - g(\theta))^T] \\ &\quad - (\psi(\theta) - g(\theta)) \mathbb{E}_\theta[(T^{(n)} - \psi(\theta))^T] + (\psi(\theta) - g(\theta))(\psi(\theta) - g(\theta))^T \\ &= \text{Var}_\theta[T^{(n)}] + 0 + 0 + (\psi(\theta) - g(\theta))(\psi(\theta) - g(\theta))^T. \end{aligned}$$

Pour montrer (2), on voit bien que $(\psi(\theta) - g(\theta))(\psi(\theta) - g(\theta))^T$ est semi-définie positive par construction (uu^T est toujours semi-définie positive).

Montrons alors (3). Posons pour cela :

$$S_\theta := T^{(n)}(X^{(n)}) - \Delta_\theta I^{(n)}(\theta)^{-1} \nabla_\theta \ln L_\theta^{(n)}(X^{(n)}) \in \mathbb{R}^m.$$

Calculons ensuite :

$$\mathbb{E}_\theta[S_\theta] = \mathbb{E}_\theta[T^{(n)}(X^{(n)})] - \Delta_\theta I^{(n)}(\theta)^{-1} \mathbb{E}_\theta[\nabla_\theta \ln L_\theta^{(n)}(X^{(n)})] = \mathbb{E}_\theta[T^{(n)}(X^{(n)})] - \Delta_\theta I^{(n)}(\theta)^{-1} \cdot 0.$$

On sait également que :

$$\begin{aligned} \text{Var}_\theta[S_\theta] &= \mathbb{E}_\theta[S_\theta S_\theta^T] - \mathbb{E}_\theta[S_\theta] \mathbb{E}_\theta[S_\theta]^T \\ &= \mathbb{E}_\theta \left[\left(T^{(n)} - \Delta_\theta I^{(n)}(\theta)^{-1} \nabla_\theta \ln L_\theta^{(n)}(X^{(n)}) \right) \left(T^{(n)} - \Delta_\theta I^{(n)}(\theta)^{-1} \nabla_\theta \ln L_\theta^{(n)}(X^{(n)}) \right)^T \right] - \psi(\theta) \psi(\theta)^T \\ &= \text{Var}_\theta[T^{(n)}] - \mathbb{E}_\theta \left[T^{(n)}(X^{(n)}) \left(\nabla_\theta \ln L_\theta^{(n)}(X^{(n)}) \right) \right] \left(I^{(n)}(\theta)^{-1} \right)^T \Delta_\theta^T \\ &\quad - \Delta_\theta I^{(n)}(\theta)^{-1} \mathbb{E}_\theta \left[\left(\nabla_\theta \ln L_\theta^{(n)}(X^{(n)}) \right) T^{(n)}(X^{(n)}) \right] \\ &\quad + \Delta_\theta I^{(n)}(\theta)^{-1} \mathbb{E}_\theta \left[\left(\nabla_\theta \ln L_\theta^{(n)}(X^{(n)}) \right) \left(\nabla_\theta \ln L_\theta^{(n)}(X^{(n)}) \right)^T \right] \left(I^{(n)}(\theta)^{-1} \right)^T \Delta_\theta^T \\ &= \text{Var}_\theta[T^{(n)}(X^{(n)})] - \Delta_\theta \left(I^{(n)}(\theta)^{-1} \right)^T \Delta_\theta^T - \Delta_\theta I^{(n)}(\theta)^{-1} \Delta_\theta^T + \Delta_\theta I^{(n)}(\theta)^{-1} I^{(n)}(\theta) \left(I^{(n)}(\theta)^{-1} \right)^T \Delta_\theta^T, \end{aligned}$$

par définition de $I^{(n)}(\theta)$. Puisque $I^{(n)}(\theta)$ est symétrique et inversible, on sait que $I^{(n)}(\theta)^{-1}$ est également symétrique. On trouve alors :

$$\text{Var}_\theta[S_\theta] = \text{Var}_\theta[T^{(n)}(X^{(n)})] - \Delta_\theta I^{(n)}(\theta)^{-1} \Delta_\theta^T - \Delta_\theta I^{(n)}(\theta)^{-1} \Delta_\theta^T + \Delta_\theta I^{(n)}(\theta)^{-1} I^{(n)}(\theta) I^{(n)}(\theta)^{-1} \Delta_\theta^T.$$

En simplifiant les produits de matrice avec leur inverse, on obtient :

$$\begin{aligned} \text{Var}_\theta[S_\theta] &= \text{Var}_\theta[T^{(n)}(X^{(n)})] - \Delta_\theta I^{(n)}(\theta)^{-1} \Delta_\theta^T - \Delta_\theta I^{(n)}(\theta)^{-1} \Delta_\theta^T + \Delta_\theta I^{(n)}(\theta)^{-1} \Delta_\theta^T \\ &= \text{Var}_\theta[T^{(n)}(X^{(n)})] - \Delta_\theta I^{(n)}(\theta)^{-1} \Delta_\theta^T \end{aligned}$$

Or $\text{Var}_\theta[S_\theta]$ est semi-définie positive par construction. Dès lors, on sait $\text{Var}_\theta[T^{(n)}(X^{(n)})] - \Delta_\theta I^{(n)}(\theta)^{-1} \Delta_\theta^T \geq 0$, ou encore $\text{Var}_\theta[T^{(n)}(X^{(n)})] \geq \Delta_\theta I^{(n)}(\theta)^{-1} \Delta_\theta^T$. \square

Définition 2.42. Dans un modèle statistique régulier, l'estimateur régulier $T^{(n)}(X^{(n)})$ de $g(\theta)$ est dit *efficace* lorsque :

$$\forall \theta \in \Theta : \text{MSE}_\theta[T^{(n)}(X^{(n)})] = \Delta_\theta I^{(n)}(\theta)^{-1} \Delta_\theta^T.$$

Remarque. Pour avoir $T^{(n)}(X^{(n)})$ efficace, il faut $g(\theta) = \psi(\theta)$ et $\text{Var}_\theta[T^{(n)}(X^{(n)})] = \Delta_\theta I^{(n)}(\theta)^{-1} \Delta_\theta^T$. L'estimateur doit donc être sans biais. De plus, la variance est définie par la borne de Cramer.

Exemple 2.12. Soient X_1, \dots, X_n iid $\mathcal{N}(\mu, \sigma_0^2)$, $g(\theta = \mu) = \mu$. On a donc $k = m = 1$. On sait que $T^{(n)}(X^{(n)}) = \bar{X}^{(n)}$ est un estimateur sans biais. Comparons alors la variance de $T^{(n)}(X^{(n)})$ avec la borne de Cramer.

$$\Delta_\mu = \frac{d}{d\mu} \psi(\mu) = \frac{d}{d\mu} \mathbb{E}_\theta[\bar{X}^{(n)}] = \frac{d}{d\mu} \mu = 1.$$

Calculons alors $I^{(n)}(\theta)$, qui est donné par :

$$I_\mu^{(n)}(x^{(n)}) = \left(\frac{1}{\sqrt{2\pi}\sigma_0} \right)^n \exp \left(-\frac{1}{2\sigma_0^2} \sum_{i=1}^n (X_i - \mu)^2 \right),$$

et donc :

$$\begin{aligned} I^{(n)}(\theta) &= \text{Var}_{\mu} \left[\frac{d}{d\mu} \ln L_{\mu}^{(n)}(X^{(n)}) \right] = \text{Var}_{\mu} \left[\frac{d}{d\mu} \left(n \ln \frac{1}{\sqrt{2\pi}\sigma_0} - \frac{1}{2\sigma_0^2} \sum_{i=1}^n (X_i - \mu)^2 \right) \right] \\ &= \frac{1}{(2\sigma_0^2)^2} \text{Var}_{\mu} \left[-2 \sum_{i=1}^n (X_i - \mu) \right] = \frac{1}{\sigma_0^4} \sum_{i=1}^n \text{Var}_{\mu}(X_i) = \frac{\sigma_0^2}{\sigma_0^4} = \frac{n}{\sigma_0^2} = \text{Var}[T^{(n)}(X^{(n)})]^{-1} = \text{MSE}_{\theta}[T^{(n)}(X^{(n)})]. \end{aligned}$$

On en déduit que l'estimateur $\bar{X}^{(n)}$ est efficace pour $g(\theta) = \mu$.

Remarque. On observe que $I^{(n)}(\theta) \propto \text{Var}_{\theta}[T^{(n)}(X^{(n)})]^{-1}$, ce qui est cohérent avec l'intuition de la notion d'information : au plus la variance est faible, au plus les observations sont groupées, et au plus il y a d'information à déduire sur θ , alors qu'au plus la variance est élevée, au plus les observations sont dispersées, et au moins il y a d'information contenue sur θ .

Exemple 2.13. X_1, \dots, X_n iid Bern(p), avec $p \in (0, 1)$. On sait que $\mathbb{E}_p[X_i] = p$ et $\text{Var}_p[X_i] = p(1-p)$. On pose $g(p) = p$. On calcule ensuite :

$$\begin{aligned} I^{(n)}(\theta) &= \text{Var}_p \left[\frac{d}{dp} \ln L_p^{(n)}(X^{(n)}) \right] = \text{Var}_p \left[\frac{d}{dp} \ln \left(p^{\sum_{i=1}^n X_i} (1-p)^{n-\sum_{i=1}^n X_i} \right) \right] \\ &= \text{Var}_p \left[\frac{d}{dp} \left(\sum_{i=1}^n X_i \ln p + \left(n - \sum_{i=1}^n X_i \right) \ln(1-p) \right) \right] \\ &= \text{Var}_p \left[\frac{1}{p} \sum_{i=1}^n X_i - \frac{1}{1-p} \left(n - \sum_{i=1}^n X_i \right) \right] = \text{Var}_p \left[\left(\frac{1}{p} + \frac{1}{1-p} \right) \sum_{i=1}^n X_i - \frac{n}{1-p} \right] \\ &= \frac{1}{(p(1-p))^2} \sum_{i=1}^n \text{Var}_p[X_i] = \frac{1}{(p(1-p))^2} n(p(1-p)) = \frac{n}{p(1-p)}. \end{aligned}$$

En prenant $T^{(n)}(X^{(n)}) = \bar{X}^{(n)}$, on a $\mathbb{E}_p[T^{(n)}(X^{(n)})] = p$, et $\text{Var}_p[T^{(n)}(X^{(n)})] = \frac{\text{Var}[X_1]}{n} = \frac{p(1-p)}{n} = I^{(n)}(\theta)^{-1}$.

À nouveau, on en déduit que $\bar{X}^{(n)}$ est un estimateur efficace.

2.4 Méthodes d'estimation

2.4.1 Méthode des moments

Plaçons-nous dans un modèle paramétrique $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), \mathcal{P}^{(n)})$, avec $\theta \in \Theta \subseteq \mathbb{R}^k$. On suppose que pour tout $1 \leq r \leq k$, on a : $\mathbb{E}_{\theta}[X_i^r] < +\infty$.

Définition 2.43. Soit $M : \Theta \rightarrow M(\Theta) : \theta \mapsto [\mu'_i(\theta)]_{1 \leq i \leq k}$. Supposons M inversible. Soit $X^{(n)}$ un vecteur d'observations de loi $\mathbb{P}_{\theta}^{(n)}$. On appelle *estimateur de θ par la méthode des moments* la statistique :

$$T^{(n)}(X^{(n)}) = M^{-1}([m'_i]_{1 \leq i \leq k}),$$

où m'_i est le moment empirique d'ordre i de θ

Exemple 2.14. Soient X_1, \dots, X_n iid $\mathcal{N}(\mu, \sigma^2)$, avec $\theta \in \Theta \subset \mathbb{R}^2$. On connaît les moments d'ordre 1 et 2 :

$$\begin{aligned}\mu'_1(\theta) &= \mathbb{E}_\theta[X_1] = \mu \\ \mu'_2(\theta) &= \mathbb{E}_\theta[X_1^2] = \text{Var}_\theta[X_1] + \mathbb{E}_\theta[X_1]^2 = \mu^2 + \sigma^2\end{aligned}$$

On a alors la fonction M donnée par :

$$M : \Theta \rightarrow M(\Theta) = \Theta : \theta = \begin{pmatrix} \mu \\ \sigma \end{pmatrix} \mapsto \begin{pmatrix} \mu \\ \mu^2 + \sigma^2 \end{pmatrix},$$

qui est bien inversible. Il faut alors résoudre le système :

$$\begin{cases} \mu'_1(\theta) = m'_1 \\ \mu'_2(\theta) = m'_2, \end{cases}$$

ce qui donne :

$$\begin{cases} \mu = \mu'_1(\theta) = m'_1 = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X} \\ \sigma^2 + \mu^2 = \mu'_2(\theta) = m'_2 = \frac{1}{n} \sum_{i=1}^n X_i^2. \end{cases}$$

On prend alors pour estimateur :

$$T^{(n)}(X^{(n)}) = \begin{pmatrix} \bar{X} \\ \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 \end{pmatrix} = \begin{pmatrix} \bar{X} \\ s^2 \end{pmatrix}.$$

Cet estimateur est convergent (car convergent en chaque composante), est exhaustif, est biaisé (car s^2 est un estimateur biaisé de σ^2), et est asymptotiquement efficace.

Exemple 2.15. Soient X_1, \dots, X_n iid $\text{Bern}(p)$, $p \in [0, 1] \subset \mathbb{R}$. On obtient :

$$p = \mu = \mu'_1(\theta) = m'_1 = \bar{X},$$

et donc on prend l'estimateur $T^{(n)}(X^{(n)}) = \bar{X}$.

Exemple 2.16. Soient X_1, \dots, X_n iid $\text{Unif}(0, \theta)$, $\theta \in \mathbb{R}^+_0 \subset \mathbb{R}$. Le système nous donne donc :

$$\frac{\theta}{2} = \mathbb{E}_\theta[X_1] = \mu'_1(\theta) = m'_1 = \bar{X}.$$

L'estimateur de θ par la méthode des moments est alors donné par :

$$T^{(n)}(X^{(n)}) = 2\bar{X}.$$

Remarque.

$$\text{MSE}_\theta[2\bar{X}] = 0^2 + \text{Var}_\theta[2\bar{X}] = \frac{4}{n} \text{Var}[X_1] \propto \frac{c}{n},$$

alors qu'un estimateur efficace a un $\text{MSE}_\theta \propto \frac{c}{n^2}$.

2.4.2 Méthode du maximum de vraisemblance

Remarque. Une notation usuelle pour noter un estimateur de θ est $\hat{\theta}$. Cette notation remplace l'estimateur $T^{(n)}(X^{(n)})$ pour lequel il faut explicitement préciser la variable estimée. $\hat{\theta}$ est une statistique, et ne dépend aucunement de θ !

L'idée d'un tel estimateur est de se baser sur la maximisation (selon θ) de la vraisemblance. On est donc tenté d'écrire :

$$\hat{\theta} = \arg \max_{\theta \in \Theta} L_{\theta}^{(n)}(X^{(n)}).$$

Or il peut arriver qu'un tel θ de soit pas unique, et donc qu'il existe plusieurs estimateurs de θ par le maximum de vraisemblance.

Définition 2.44. L'estimateur $\hat{\theta}$ est un estimateur de θ par la méthode du maximum de vraisemblance lorsque :

$$\forall \theta \in \Theta : L_{\hat{\theta}}^{(n)}(X^{(n)}) \geq L_{\theta}^{(n)}(X^{(n)}).$$

Exemple 2.17. Soient X_1, \dots, X_n iid Unif $\left(\left[\theta - \frac{1}{2}, \theta + \frac{1}{2} \right] \right)$, avec $\theta \in \mathbb{R}$. On peut écrire la vraisemblance :

$$L_{\theta}^{(n)}(X^{(n)}) = \prod_{i=1}^n f_{\theta}^{X_i}(X_i) = \prod_{i=1}^n I_{[\theta - \frac{1}{2} \leq X_i \leq \theta + \frac{1}{2}]} = I_{[\theta - \frac{1}{2} \leq X_{(1)}]} I_{[X_{(n)} \leq \theta + \frac{1}{2}]} = I_{[X_{(n)} - \frac{1}{2} \leq \theta \leq X_{(1)} + \frac{1}{2}]}.$$

La fonction de vraisemblance valant ici soit 1 soit 0, toute valeur de θ telle que $\theta \in \left[X_{(n)} - \frac{1}{2}, X_{(1)} + \frac{1}{2} \right]$ maximise la vraisemblance.

Exemple 2.18. Soient X_1, \dots, X_n iid Unif $(0, \theta)$, avec $\theta \in \mathbb{R}^+_0$. Ici, la fonction de vraisemblance ne vaut plus uniquement 0 ou 1 :

$$L_{\theta}^{(n)}(X^{(n)}) = \frac{1}{\theta^n} I_{[0 \leq X_{(1)}]} I_{[X_{(n)} \leq \theta]} = \frac{1}{\theta^n} I_{[0 \leq \theta \leq X_{(n)}]}.$$

Pour $\theta \in [0, X_{(n)}]$, la fonction de vraisemblance est nulle, et puis vaut θ^{-n} pour $\theta \geq X_{(n)}$. Le maximum est donc en $\theta = X_{(n)}$.

De plus, la fonction $\theta \mapsto \theta^{-n}$ est strictement décroissante, donc le maximum de vraisemblance est unique.

Remarque. Par le critère de factorisation de Neymann-Fisher, si $S(X^{(n)})$ est une statistique exhaustive, on sait :

$$L_{\theta}^{(n)}(X^{(n)}) = (g_{\theta} \circ S)(X^{(n)}) \cdot h(X^{(n)}).$$

Donc (en considérant $\arg \max$ comme l'ensemble des arguments maximisant la valeur), on a :

$$\hat{\theta} \in \arg \max_{\theta \in \Theta} L_{\theta}^{(n)}(X^{(n)}) = \arg \max_{\theta \in \Theta} (g_{\theta} \circ S)(X^{(n)}) = (\alpha \circ S)(X^{(n)}).$$

Cela implique que dans le cas du maximum de vraisemblance, l'estimateur dépend toujours des observations à travers une statistique exhaustive.

Proposition 2.45. Si $\theta \mapsto L_{\theta}^{(n)}(X^{(n)})$ est différentiable sur $\text{int}(\Theta)$, alors tout estimateur du maximum de vraisemblance à valeurs dans $\text{int}(\Theta)$ vérifie :

$$\nabla_{\theta} L_{\theta}^{(n)}(X^{(n)}) \Big|_{\theta=\hat{\theta}} = 0.$$

Remarque. Par continuité et croissance stricte de $\ln(\cdot)$, on sait également que :

$$\nabla_{\theta} \ln \left(L_{\theta}^{(n)}(X^{(n)}) \right) \Big|_{\theta=\hat{\theta}} = 0.$$

L'intérêt de passer par un logarithme est de transformer les produits en somme, ce qui est plus agréable à dériver.

Exemple 2.19. Soient X_1, \dots, X_n iid $\text{Bern}(p)$. On peut calculer la fonction de vraisemblance :

$$L_p^{(n)}(X^{(n)}) = \prod_{i=1}^n p^{X_i} (1-p)^{1-X_i} = p^{\sum_{i=1}^n X_i} (1-p)^{n-\sum_{i=1}^n X_i} = p^{n\bar{X}} (1-p)^{n(1-\bar{X})}.$$

Annulons ensuite le gradient de $\ln \circ L_p^{(n)}$:

$$0 = \frac{\partial}{\partial p} = n\bar{X} \frac{\partial}{\partial p} \ln p + n(1-\bar{X}) \frac{\partial}{\partial p} \ln(1-p) = n\bar{X} \frac{1}{p} + n(\bar{X}-1) \frac{1}{1-p}.$$

En multipliant par $p(1-p)$ de part et d'autre ,on obtient :

$$0 = n\bar{X}(1-p) + n(\bar{X}-1)p = n\bar{X} - n\bar{X}p + n\bar{X}p - np = n\bar{X} - np,$$

ou encore $p = \bar{X}$. Dès lors, $\hat{p} = \bar{X}$ est un estimateur de p par le maximum de vraisemblance.

Proposition 2.46. Soit $g : \Theta \rightarrow g(\Theta)$. Alors :

$$\forall \theta \in \Theta : \widehat{g(\theta)} = g(\hat{\theta}).$$

Démonstration. Distinguons les deux cas où g est bijective, et où g n'est pas bijective.

Si g est bijective, alors c'est évident car $g(\theta)$ transforme juste le paramètre de manière univoque.

Si g n'est pas bijective, on observe que g est surjective par construction. Et donc g n'est pas injective. On pose alors :

$$G : \Theta \rightarrow g(\Theta) \times \Theta : \theta \mapsto \begin{pmatrix} g(\theta) \\ \theta \end{pmatrix}.$$

G est injective par construction, et donc est bijective (car surjective en chaque composante). On sait donc que :

$$\widehat{G(\theta)} = G(\hat{\theta}),$$

ce qui implique l'égalité composante par composante, et donc :

$$\widehat{g(\theta)} = g(\hat{\theta}).$$

□

Définition 2.47. Soit $\hat{\theta}$ un estimateur. On dit qu'il est *asymptotiquement efficace* lorsque :

$$\text{Var}_{\theta}[\hat{\theta}] = \frac{1}{nI^{(1)}(\theta)}.$$

Exemple 2.20. Prenons X_1, \dots, X_n iid $\mathbb{P}_{\theta}^{(1)}$, avec $\theta \in \Theta \subseteq \mathbb{R}$. Par la loi des grands nombres, on a :

$$\forall \theta \in \Theta : \hat{\theta} \xrightarrow[n \rightarrow +\infty]{\text{p.s.}} \theta \quad \text{sous } \mathbb{P}_{\theta}^{(1)}.$$

On a également :

$$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow[n \rightarrow +\infty]{\mathcal{D}} \mathcal{N}\left(0, \frac{1}{I^{(1)}(\theta)}\right).$$

Pour $n \gg$, on a :

$$\hat{\theta} \approx \mathcal{N}\left(\theta, \frac{1}{nI^{(1)}(\theta)}\right),$$

et donc :

$$\begin{aligned}\mathbb{E}_{\theta}[\hat{\theta}] &\approx \theta \\ \text{Var}_{\theta}[\hat{\theta}] &\approx \frac{1}{nI^{(1)}(\theta)}.\end{aligned}$$

On sait dès lors que pour n grand, on a :

$$\text{MSE}_{\theta}[\hat{\theta}] \approx b_{\theta}(\hat{\theta})^2 + \text{Var}_{\theta}[\hat{\theta}] = \text{Var}_{\theta}[\hat{\theta}] = \frac{1}{nI^{(1)}(\theta)},$$

qui est la borne de Cramer-Rao. $\hat{\theta}$ est donc asymptotiquement efficace.

2.4.3 Comportement asymptotique des estimateurs du maximum de vraisemblance

On se place dans un modèle statistique $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), \mathcal{P}^{(n)} = \{\mathbb{P}_{\theta}^{(n)} \text{ t.q. } \theta \in \Theta \subseteq \mathbb{R}\})$ d'échantillonnage.

On considère les hypothèses suivantes :

H1 Θ est ouvert ;

H2 $\mathcal{X} = \{x \in \mathbb{R} \text{ t.q. } L_{\theta}^{(1)}(x) > 0\}$ ne dépend pas de θ ;

H3 $\forall x \in \mathcal{X} : \theta \mapsto L_{\theta}^{(1)}(x)$ est dérivable sur Θ et $\theta \mapsto \frac{d}{d\theta} L_{\theta}^{(1)}(x)$ est dérivable sur Θ ;

H4 l'expression $\int_{\mathcal{X}} L_{\theta}^{(1)}(x) dx$ peut être dérivée sous le signe deux fois ;

H5 $I^{(1)}(\theta) = \int_{\mathcal{X}} \left(\frac{d}{d\theta} \ln L_{\theta}^{(1)}(x) \right)^2 dx$ est fini et $\neq 0$;

H6 Pour toute suite $(\theta_n)_n$ convergente en $\theta \in \Theta$, on a :

$$\sup_{x \in \mathcal{X}} |B_{\theta_n}^{(1)}(x) - B_{\theta}^{(1)}(x)| \xrightarrow{n \rightarrow +\infty} 0,$$

$$\text{avec } B_{\theta}^{(1)}(x) = \frac{d^2}{d\theta^2} \ln L_{\theta}^{(1)}(x).$$

Remarque. À nouveau :

$$0 = \frac{d}{d\theta} 1 = \frac{d}{d\theta} \int_{\mathcal{X}} L_{\theta}^{(1)}(x) dx = \int_{\mathcal{X}} \frac{d}{d\theta} L_{\theta}^{(1)}(x) dx = \int_{\mathcal{X}} \left(\frac{d}{d\theta} \ln L_{\theta}^{(1)}(x) \right) L_{\theta}^{(1)}(x) dx = \mathbb{E}_{\theta} \left[\frac{d}{d\theta} \ln L_{\theta}^{(1)}(X_1) \right],$$

et donc :

$$I^{(1)}(\theta) = \mathbb{E}_{\theta} \left[\left(\frac{d}{d\theta} \ln L_{\theta}^{(1)}(X_1) \right)^2 \right] = \text{Var}_{\theta} \left[\frac{d}{d\theta} \ln L_{\theta}^{(1)}(X) \right].$$

Également, on sait :

$$0 = \frac{d}{d\theta} \int_{\mathcal{X}} \left(\ln L_{\theta}^{(1)}(x) \right) L_{\theta}^{(1)}(x) dx = \int_{\mathcal{X}} \left(\left(\frac{d^2}{d\theta^2} \ln L_{\theta}^{(1)}(x) \right) L_{\theta}^{(1)}(x) + \left(\frac{d}{d\theta} \ln L_{\theta}^{(1)}(x) \right) \frac{d}{d\theta} L_{\theta}^{(1)}(x) \right) dx.$$

On en déduit :

$$0 = \mathbb{E}_{\theta} \left[\frac{d^2}{d\theta^2} \ln L_{\theta}^{(1)}(X_1) \right] + \mathbb{E}_{\theta} \left[\left(\frac{d}{d\theta} \ln L_{\theta}^{(1)}(X_1) \right)^2 \right] = \mathbb{E}_{\theta} \left[\frac{d^2}{d\theta^2} \ln L_{\theta}^{(1)}(X_1) \right] + I^{(1)}(\theta),$$

ou encore :

$$I^{(1)}(\theta) = -\mathbb{E}_{\theta} \left[\frac{d^2}{d\theta^2} \ln L_{\theta}^{(1)}(X_1) \right].$$

Théorème 2.48. Si le modèle satisfait (H1)-(H6), alors :

(i) il existe une suite $(T^{(n)}(X^{(n)}))_{n \in \mathbb{N}}$ de solutions de l'équation de vraisemblance :

$$\frac{d}{d\theta} \ln L_{\theta}^{(n)}(X^{(n)}) = 0$$

qui est fortement convergente pour θ , c-à-d :

$$\forall \theta \in \Theta : T^{(n)}(X^{(n)}) \xrightarrow[n \rightarrow +\infty]{p.s.} \theta \text{ sous } \mathbb{P}_{\theta}^{(n)}$$

(ii) pour toute telle suite $(T^{(n)}(X^{(n)}))_n$, on a :

$$\forall \theta \in \Theta : \sqrt{n}(T^{(n)}(X^{(n)}) - \theta) \xrightarrow[n \rightarrow +\infty]{\mathcal{D}} \mathcal{N}(0, I^{(1)}(\theta)^{-1}).$$

Remarque. (ii) implique que $T^{(n)}(X^{(n)})$ est asymptotiquement efficace.

Démonstration. Supposons que (i) est vrai et montrons (ii). Posons :

$$A_{\theta}^{(n)}(x^{(n)}) := \frac{1}{n} \frac{d}{d\theta} \ln L_{\theta}^{(n)}(x^{(n)})$$

$$B_{\theta}^{(n)}(x^{(n)}) := \frac{1}{n} \frac{d^2}{d\theta^2} \ln L_{\theta}^{(n)}(x^{(n)}).$$

On remarque :

$$A_{\theta}^{(n)}(x^{(n)}) = \frac{1}{n} \sum_{i=1}^n A_{\theta}^{(1)}(x_i) \quad \text{et} \quad B_{\theta}^{(n)}(x^{(n)}) = \frac{1}{n} \sum_{i=1}^n B_{\theta}^{(1)}(x_i).$$

Par définition de $T^{(n)}(X^{(n)})$, pour tout n , on a :

$$\left. \frac{d}{d\theta} \ln L_{\theta}(X^{(n)}) \right|_{\theta=T^{(n)}(X^{(n)})} = 0,$$

et donc :

$$A_{T^{(n)}(X^{(n)})}(X^{(n)}) = \frac{1}{n} \frac{d}{d\theta} \ln L_{\theta}(X^{(n)}) = 0.$$

On en déduit :

$$\forall n : 0 = A_{T^{(n)}(X^{(n)})}^{(n)}(X^{(n)}) = A_{\theta}^{(n)}(X^{(n)}) + \left. \frac{d}{d\theta} A_{\theta}^{(n)}(X^{(n)}) \right|_{T^{(n)}(X^{(n)})} (X^{(n)}) \cdot (T^{(n)}(X^{(n)}) - \theta),$$

et donc (théorème des accroissements finis) :

$$T_{*}^{(n)} = \frac{-A_{\theta}^{(n)}(X^{(n)})}{\left. \frac{d}{d\theta} A_{\theta}^{(n)}(X^{(n)}) \right|_{\theta=T_{*}^{(n)}(X^{(n)})}} = \frac{-A_{\theta}^{(n)}(X^{(n)})}{B_{T_{*}^{(n)}(X^{(n)})}^{(n)}(X^{(n)})},$$

pour $T_{*}^{(n)}(X^{(n)}) \in [0, T^{(n)}(X^{(n)})]$

On a alors :

$$\sqrt{n} \left(T^{(n)}(X^{(n)}) - \theta \right) = \frac{-\sqrt{n} A_{\theta}^{(n)}(X^{(n)})}{B_{T_{*}^{(n)}(X^{(n)})}^{(n)}(X^{(n)})}.$$

Montrons indépendamment la convergence du numérateur et celle du dénominateur.

Convergence du numérateur :

$$-\sqrt{n}A_{\theta}^{(n)}(X^{(n)}) = \frac{1}{\sqrt{n}} \sum_{i=1}^n \left(-A_{\theta}^{(n)}(X^{(n)}) \right) \xrightarrow[n \rightarrow +\infty]{\mathcal{D} \text{ sous } \mathbb{P}_{\theta}^{(n)}} \mathcal{N}(-\mathbb{E}_{\theta}[A_{\theta}^{(1)}(X_1)], I^{(1)}(\theta)) = \mathcal{N}(0, \mathbb{E}_{\theta}[(A_{\theta}^{(1)}(X^{(n)}))^2]).$$

Convergence du dénominateur :

$$\begin{aligned} B_{T_{*}^{(n)}(X^{(n)})}^{(1)}(X^{(n)}) &= \frac{1}{n} \sum_{i=1}^n B_{T_{*}^{(n)}}^{(1)}(X_i) = \frac{1}{n} \sum_{i=1}^n B_{\theta}^{(1)}(X_i) + \frac{1}{n} \sum_{i=1}^n \left(B_{T_{*}^{(n)}}^{(1)}(X_i) - B_{\theta}^{(1)}(X_i) \right) \\ &= -I^{(1)}(\theta) + \frac{1}{n} \sum_{i=1}^n \left(B_{T_{*}^{(n)}(X_i)}^{(1)}(X^{(n)}) - B_{\theta}^{(1)}(X_i) \right). \end{aligned}$$

Par inégalité triangulaire, on peut dire :

$$\begin{aligned} \left| \frac{1}{n} \sum_{i=1}^n \left(B_{T_{*}^{(n)}(X^{(n)})}^{(1)}(X_i) - B_{\theta}^{(1)}(X_i) \right) \right| &\leq \frac{1}{n} \sum_{i=1}^n \left| B_{T_{*}^{(n)}(X^{(n)})}^{(1)}(X_i) - B_{\theta}^{(1)}(X_i) \right| \\ &\leq \frac{1}{n} \sum_{i=1}^n \sup_{x \in \mathcal{X}} \left| B_{T_{*}^{(n)}(X^{(n)})}^{(1)}(x) - B_{\theta}^{(1)}(x) \right| \\ &= \sup_{x \in \mathcal{X}} \left| B_{T_{*}^{(n)}(X^{(n)})}^{(1)}(x) - B_{\theta}^{(1)}(x) \right|, \end{aligned}$$

ce qui, par (H6) converge presque sûrement vers 0.

Le lemme de Slutsky nous affirme alors que :

$$\sqrt{n} \left(T^{(n)}(X^{(n)}) - \theta \right) \xrightarrow[n \rightarrow +\infty]{\mathcal{D} \text{ sous } \mathbb{P}_{\theta}^{(n)}} \frac{\mathcal{N}(0, I^{(1)}(\theta))}{(I^{(1)}(\theta))^2} = \mathcal{N}(0, I^{(1)}(\theta)^{-1}).$$

□

Chapitre 3

Tests d'hypothèse

En se plaçant dans le modèle statistique $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), \mathcal{P}^{(n)})$, avec $\mathcal{P}^{(n)} = \{\mathbb{P}_\theta^{(n)} \text{ t.q. } \theta \in \Theta\}$. On partitionne Θ en $\Theta_0 \subseteq \Theta$ et $\Theta = \Theta_0 \cup \Theta_1$.

On parle de *problème de test d'hypothèse* pour :

$$\begin{cases} H_0 : \theta \in \Theta_0 & \text{hypothèse nulle,} \\ H_1 : \theta \in \Theta_1 & \text{contre-hypothèse.} \end{cases} \quad (3.1)$$

Il y a deux choix possibles, à savoir RH_0 , le rejet de H_0 , et $\text{RH}\bar{0}$, le non-rejet de H_0 .

Exemple 3.1. Soient X_1, \dots, X_n iid $\mathcal{N}(\mu, \sigma^2)$, avec $\theta = [\mu, \sigma^2]^T \in \Theta \subsetneq \mathbb{R}^2$. Voici une partition de Θ :

$$\Theta : \Theta_0 \sqcup \Theta_1 = \left\{ [\mu, \sigma^2]^T \in \Theta \text{ t.q. } \mu > 15 \right\} \sqcup \left\{ [\mu, \sigma^2]^T \in \Theta \text{ t.q. } \mu \leq 15 \right\}.$$

$$\begin{cases} \theta \in \Theta_0 \\ \theta \in \Theta_1 \end{cases}$$

Exemple 3.2. Soient X_1, \dots, X_n iid $\text{Bern}(p)$, pour $p \in [0, 1] \subset \mathbb{R}$. Soit $p_0 \in [0, 1]$. Voici un test d'hypothèse :

$$\begin{cases} H_0 : p \in [0, p_0], \\ H_1 : p \in (p_0, 1]. \end{cases}$$

Définition 3.1. On dit que le problème est *unilatéral* s'il est sous la forme :

$$\begin{cases} H_0 : \theta \leq \theta_0 \\ H_1 : \theta > \theta_0 \end{cases}$$

(une partition de Θ en deux espaces de mesure non-nulle).

On dit que le problème est *bilatéral* s'il est sous la forme :

$$\begin{cases} H_0 : \theta = \theta_0 \\ H_1 : \theta \neq \theta_0 \end{cases} \quad (3.2)$$

(une partition de Θ en un singleton et Θ moins un point).

Dans ce cas, on dit que $H_0 : \theta = \theta_0$ est l'*hypothèse simple*, et $H_1 : \theta \neq \theta_0$ est l'*hypothèse composée*.

Définition 3.2. Un test pur est une fonction mesurable $\phi^{(n)} : \mathcal{X}^{(n)} \rightarrow \{0, 1\}$, où \mathcal{X} est l'ensemble des valeurs observables pour $X^{(n)}$.

Définition 3.3. On appelle *zone critique* l'ensemble :

$$\left(\phi^{(n)}\right)^{-1}(\{1\}).$$

Définition 3.4. Un test randomisé (ou test impur) est une fonction mesurable $\phi^{(n)} : \mathcal{X}^{(n)} \rightarrow [0, 1]$.

Remarque. Soit $\gamma := \phi^{(n)}(x^{(n)})$. Si $\gamma = 0$, alors RH0. Si $\gamma = 1$, alors RH1. Et si $\gamma \in (0, 1)$, alors RH0 avec probabilité γ .

De plus :

$$\mathbb{E}_\theta[\phi^{(n)}(X^{(n)})] = \int_{\mathcal{X}^{(n)}} \phi^{(n)}(x^{(n)}) L_\theta^{(n)}(x^{(n)}) dx^{(n)} = \int_{\mathcal{X}^{(n)}} \mathbb{P}[\text{RH0} | X^{(n)} = x^{(n)}] L_\theta^{(n)}(x^{(n)}) dx^{(n)} = \mathbb{P}[\text{RH0}].$$

Définition 3.5. Le risque de première espèce en $\theta \in \Theta_0$ est la valeur :

$$\mathbb{P}_\theta[\phi^{(n)}(X^{(n)}) \text{ rejette}] = \mathbb{E}_\theta[\phi^{(n)}(X^{(n)})].$$

Le risque de seconde espèce en $\theta \in \Theta_1$ est la valeur :

$$\mathbb{P}_\theta[\phi^{(n)}(X^{(n)}) \text{ ne rejette pas}] = 1 - \mathbb{E}_\theta[\phi^{(n)}(X^{(n)})].$$

Définition 3.6. La dimension d'un test $\phi^{(n)}$ en $\theta \in \Theta_0$ est $\mathbb{E}_\theta[\phi^{(n)}(X^{(n)})]$.

La puissance d'un test $\phi^{(n)}$ en $\theta \in \Theta_1$ est $\mathbb{E}_\theta[\phi^{(n)}(X^{(n)})]$.

3.1 Principe de Neyman

Définition 3.7. Soit $\phi^{(n)}$ un test (pur ou randomisé). On dit que $\phi^{(n)}$ est de niveau $\alpha \in (0, 1)$ lorsque :

$$\forall \theta \in \Theta : \mathbb{E}_\theta^{(n)}[\phi^{(n)}(X^{(n)})] \leq \alpha.$$

Définition 3.8. Le test ϕ_* est dit à *puissance uniformément maximale* (PUM) dans la classe C_α lorsque :

- $\phi_* \in C_\alpha$;
- $\forall \phi \in C_\alpha : \forall \theta \in \Theta_1 : \mathbb{E}_\theta^{(n)}[\phi_*(X^{(n)})] \geq \mathbb{E}_\theta^{(n)}[\phi^{(n)}(X^{(n)})]$.

Considérons ici le test le plus simple possible :

$$\begin{cases} H_0 : \theta = \theta_0 \\ H_1 : \theta = \theta_1 \end{cases} \quad (3.3)$$

où $\Theta = \{\theta_0, \theta_1\}$. Pour $\alpha \in (0, 1)$, la classe C_α est donc :

$$C_\alpha = \left\{ \phi : \mathcal{X}^{(n)} \rightarrow [0, 1] \text{ t.q. } \mathbb{E}_{\theta_0}^{(n)}[\phi(X^{(n)})] \leq \alpha \right\}.$$

Théorème 3.9 (Lemme fondamental de Neyman). Soit le problème d'hypothèse (3.3). Soit $\alpha \in (0, 1)$ et notons $L_\theta^{(n)}$ la vraisemblance associée à $\mathbb{P}_\theta^{(n)}$. Alors :

- (i) il existe $(k_\alpha, \gamma_\alpha) \in \mathbb{R}^+ \times [0, 1]$ tels que le test ϕ_* défini par :

$$\phi_*(x^{(n)}) = \begin{cases} 1 & \text{si } L_{\theta_1}^{(n)}(x^{(n)}) > k_\alpha L_{\theta_0}^{(n)}(x^{(n)}) \\ \gamma_\alpha & \text{si } L_{\theta_1}^{(n)}(x^{(n)}) = k_\alpha L_{\theta_0}^{(n)}(x^{(n)}) \\ 0 & \text{si } L_{\theta_1}^{(n)}(x^{(n)}) < k_\alpha L_{\theta_0}^{(n)}(x^{(n)}) \end{cases}$$

vérifie $\mathbb{E}_{\theta_0}[\phi_*] \leq \alpha$;

— ϕ_* est à puissance uniformément maximale dans C_α .

Démonstration. Soit F_{θ_0} la fonction de répartition de la valeur aléatoire $Y^{(n)} := \frac{L_{\theta_1}^{(n)}(X^{(n)})}{L_{\theta_0}^{(n)}(X^{(n)})}$ sous $\mathbb{P}_{\theta_0}^{(n)}$, et posons $L_{\theta_0}^{(n)}(X^{(n)}) = 0 \Rightarrow Y^{(n)} = +\infty$.

Pour $z \in \mathbb{R}$, on peut alors écrire :

$$\mathbb{E}_{\theta_0}^{(n)}[\phi_*] = \mathbb{P}_{\theta_0}[Y^{(n)} > k_\alpha] + \gamma_\alpha \mathbb{P}[Y = k_\alpha] = 1 - F_{\theta_0}(k_\alpha) + \lim_{\varepsilon \rightarrow 0} \gamma_\alpha (F_{\theta_0}(k_\alpha) - F_{\theta_0}(k_\alpha - \varepsilon)).$$

Distinguons deux cas :

— s'il existe $x \in \mathbb{R}$ tel que $F_{\theta_0}(z) = 1 - \alpha$, alors on pose

$$(k_\alpha, \gamma_\alpha) = (z, 0).$$

On a alors bien :

$$\mathbb{E}_{\theta_0}^{(n)}[\phi_*(X^{(n)})] = 1 - F_{\theta_0}(z) + 0 = \alpha.$$

— Sinon, on pose :

$$k_\alpha := \inf\{z \in \mathbb{R} \text{ t.q. } F_{\theta_0}(z) \geq 1 - \alpha\}.$$

Puisque $Y \geq 0$ (quotient de vraisemblances, qui sont positives), on sait $k_\alpha \geq 0$. Par continuité de F_{θ_0} (induite par la dérivabilité de F_{θ_0}), on a :

$$F_{\theta_0}(k_\alpha - \varepsilon) < 1 - \alpha < F_{\theta_0}(k_\alpha).$$

On pose donc :

$$\gamma_\alpha := \lim_{\varepsilon \rightarrow 0} \frac{F_{\theta_0}(k_\alpha) - (1 - \alpha)}{F_{\theta_0}(k_\alpha) - F_{\theta_0}(k_\alpha - \varepsilon)} \in (0, 1).$$

On a alors en effet :

$$\begin{aligned} \mathbb{E}_{\theta_0}^{(n)}[\phi_*(X^{(n)})] &= 1 - F_{\theta_0}(k_\alpha) + \lim_{\varepsilon \rightarrow 0} \frac{F_{\theta_0}(k_\alpha) - (1 - \alpha)}{F_{\theta_0}(k_\alpha) - F_{\theta_0}(k_\alpha - \varepsilon)} (F_{\theta_0}(k_\alpha) - F_{\theta_0}(k_\alpha - \varepsilon)) \\ &= 1 - F_{\theta_0}(k_\alpha) + (F_{\theta_0}(k_\alpha) - (1 - \alpha)) = 1 - 1 + \alpha = \alpha. \end{aligned}$$

Montrons alors le point 2. Prenons $\phi \in C_\alpha$, et considérons la fonction g définie par :

$$g : \mathcal{X}^{(n)} \rightarrow \mathbb{R} : x^{(n)} \mapsto \left((\phi_* - \phi)(x^{(n)}) \right) \left((L_{\theta_1} - k_\alpha L_{\theta_0})(x^{(n)}) \right).$$

Observons que g est définie positive car :

$$\begin{aligned} \forall x^{(n)} \in \mathcal{X}^{(n)} : \quad & \left(L_{\theta_1}^{(n)}(x^{(n)}) - k_\alpha L_{\theta_0}^{(n)}(x^{(n)}) \geq 0 \right) \Rightarrow \left(\phi_*(x^{(n)}) - \phi(x^{(n)}) = 1 - \phi(x^{(n)}) \geq 0 \right), \\ \text{et} \quad & \left(L_{\theta_1}^{(n)}(x^{(n)}) - k_\alpha L_{\theta_0}^{(n)}(x^{(n)}) \leq 0 \right) \Rightarrow \left(\phi_*(x^{(n)}) - \phi(x^{(n)}) = 0 - \phi(x^{(n)}) \leq 0 \right). \end{aligned}$$

On peut dès lors écrire, en distribuant g :

$$\begin{aligned} 0 &\leq \int_{\mathcal{X}^{(n)}} g(x^{(n)}) dx^{(n)} = \int_{\mathcal{X}^{(n)}} \left(\phi_*(x^{(n)}) - \phi(x^{(n)}) \right) L_{\theta_1}(x^{(n)}) dx^{(n)} - k_\alpha \left(\int_{\mathcal{X}^{(n)}} \left(\phi_*(x^{(n)}) - \phi(x^{(n)}) \right) L_{\theta_0} dx^{(n)} \right) \\ &= \mathbb{E}_{\theta_1}^{(n)}[\phi_*(X^{(n)}) - \phi(X^{(n)})] + k_\alpha (\mathbb{E}_{\theta_0}^{(n)}[\phi_*(X^{(n)}) - \phi(X^{(n)})]) \\ &= \mathbb{E}_{\theta_1}^{(n)}[\phi_*(X^{(n)})] - \mathbb{E}_{\theta_1}[\phi(X^{(n)})] - k_\alpha (\alpha - \mathbb{E}_{\theta_0}[\phi(X^{(n)})]). \end{aligned}$$

Or, comme $\mathbb{E}_{\theta_0}[\phi(X^{(n)})] < \alpha$ (car $\phi \in C_\alpha$), on a :

$$\mathbb{E}_{\theta_1}^{(n)}[\phi_*(X^{(n)})] \geq \mathbb{E}_{\theta_0}^{(n)}[\phi(X^{(n)})] + k_\alpha(\alpha - \mathbb{E}_{\theta_0}[\phi(X^{(n)})]) \geq \mathbb{E}_{\theta_1}[\phi(X^{(n)})].$$

□

Théorème 3.10. *Selon les hypothèses du lemme fondamental de Neyman, si ϕ est de niveau $\alpha \in (0, 1)$ et est de même puissance que ϕ_* , i.e. ils ont la même espérance sous θ_1 , alors il existe une fonction $\gamma_\alpha : \mathcal{X}^{(n)} \rightarrow [0, 1]$ telle que :*

$$\forall x^{(n)} \in \mathcal{X}^{(n)} : \phi(x^{(n)}) = \begin{cases} 1 & \text{si } L_{\theta_1}(x^{(n)}) < k_\alpha L_{\theta_0}(x^{(n)}) \\ \gamma_\alpha(x^{(n)}) & \text{si } L_{\theta_1}(x^{(n)}) = k_\alpha L_{\theta_0}(x^{(n)}) \\ 0 & \text{sinon,} \end{cases}$$

où k_α est celui de ϕ_* , et où le $\forall x^{(n)} \in \mathcal{X}^{(n)}$ signifie pour tout $x^{(n)}$ dans $\mathcal{X}^{(n)}$, sauf un ensemble de mesure nulle.

De plus, $\mathbb{E}_{\theta_1}[\phi_*(X^{(n)})] > \alpha$.

Démonstration. On sait que :

$$-k_\alpha(\alpha - \mathbb{E}_{\theta_0}[\phi(X^{(n)})]) = \mathbb{E}_{\theta_1}^{(n)}[\phi_*(X^{(n)})] - \mathbb{E}_{\theta_1}^{(n)}[\phi(X^{(n)})] - k_\alpha(\alpha - \mathbb{E}_{\theta_0}^{(n)}[\phi(X^{(n)})]) \geq 0.$$

Or, on sait que $k_\alpha(\alpha - \mathbb{E}_{\theta_0}^{(n)}[\phi(X^{(n)})]) \geq 0$. On a donc $\mathbb{E}_{\theta_0}^{(n)}[\phi(X^{(n)})] = \alpha$, et donc :

$$\int_{\mathcal{X}^{(n)}} g(x^{(n)}) dx^{(n)} = 0,$$

c'est à dire, pour tout $x^{(n)} \in \mathcal{X}^{(n)} \setminus T$, tel que T est de mesure nulle, on a :

$$(\phi_*(x^{(n)}) - \phi(x^{(n)})) \cdot (L_{\theta_1}^{(n)}(x^{(n)}) - k_\alpha L_{\theta_0}^{(n)}(x^{(n)})) = 0.$$

Soit un tel $x^{(n)} \in \mathcal{X}^{(n)} \setminus T$. Si $L_{\theta_1}^{(n)}(x^{(n)}) \neq k_\alpha L_{\theta_0}^{(n)}(x^{(n)})$, alors :

$$0 = \phi_*(x^{(n)}) - \phi(x^{(n)}).$$

De plus, on pose $\gamma_\alpha = \phi$ sur $\{x^{(n)} \in \mathcal{X}^{(n)} \text{ t.q. } L_{\theta_1}^{(n)}(x^{(n)}) = k_\alpha L_{\theta_0}^{(n)}(x^{(n)})\}$.

Montrons que $\mathbb{E}_{\theta_1}[\phi_*(X^{(n)})] \geq \alpha$. Posons $\phi_\alpha : x^{(n)} \mapsto \alpha$. On sait que ϕ_* est de puissance maximale, donc :

$$\mathbb{E}_{\theta_1}[\phi_*(X^{(n)})] \geq \mathbb{E}_{\theta_1}[\phi_\alpha(X^{(n)})] = \alpha.$$

Supposons par l'absurde que $\mathbb{E}_{\theta_1}[\phi_*(X^{(n)})] = \alpha \in (0, 1)$. Par la première partie du théorème, on a :

$$\alpha = \phi_\alpha(x^{(n)}) \notin \{0, 1\}.$$

Donc :

$$\forall x^{(n)} \in \mathcal{X}^{(n)} \setminus T : L_{\theta_1}^{(n)}(x^{(n)}) = k_\alpha L_{\theta_0}^{(n)}(x^{(n)}).$$

En intégrant, on trouve :

$$1 = \int_{\mathcal{X}^{(n)}} L_{\theta_1}^{(n)}(x^{(n)}) dx^{(n)} = k_\alpha \int_{\mathcal{X}^{(n)}} L_{\theta_0}^{(n)}(x^{(n)}) dx^{(n)} = k_\alpha,$$

et donc $L_{\theta_0}^{(n)} = L_{\theta_1}^{(n)}$ sur $\mathcal{X}^{(n)} \setminus T$.

Pour $B \in \mathcal{B}(\mathbb{R}^n)$, on a alors $\mathbb{P}_{\theta_0}[B] = \mathbb{P}_{\theta_1}[B]$, ce qui est une contradiction car $\theta_0 \neq \theta_1$.

□

3.2 Tests unilatéraux à puissance uniformément maximale

Définition 3.11. Soit le modèle statistique $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), \mathcal{P}^{(n)})$, avec $\mathcal{P} = \{\mathbb{P}_\theta \text{ t.q. } \theta \in \Theta \subseteq \mathbb{R}\}$. Ce modèle est dit à *vraisemblance monotone* en la statistique $T(x^{(n)})$ lorsque :

$$\forall \theta', \theta'' \in \Theta : \theta' < \theta'' \Rightarrow \exists h_{\theta', \theta''} \text{ strict. croissante t.q. } h_{\theta', \theta''}(T(x^{(n)})) = \frac{L_{\theta''}^{(n)}(x^{(n)})}{L_{\theta'}^{(n)}(x^{(n)})}.$$

Théorème 3.12. Soit un modèle statistique à vraisemblance monotone en une statistique $T(x^{(n)})$ et soit $\alpha \in (0, 1)$. Alors :

— $\exists (t_\alpha^+, \gamma_\alpha) \in \mathbb{R} \times [0, 1]$ t.q. ϕ_{*T}^+ défini par :

$$\phi_{*T}^+(x^{(n)}) = \begin{cases} 1 & \text{si } T(x^{(n)}) > t_\alpha^+ \\ \gamma_\alpha & \text{si } T(x^{(n)}) = t_\alpha^+ \\ 0 & \text{sinon} \end{cases}$$

vérifie $\mathbb{E}_{\theta_0}^{(n)}[\phi_{*T}^+(X^{(n)})] = \alpha$;

— la fonction $\theta \mapsto \mathbb{E}_\theta[\phi_{*T}^+(X^{(n)})]$ est strictement croissante;

— le test ϕ_{*T}^+ est à PUM dans la classe des tests de niveau α pour le problème d'hypothèse :

$$\begin{cases} H_0 : \theta \leq \theta_0 \\ H_1 : \theta > \theta_0 \end{cases} \quad (3.4)$$

avec $\theta_0 \in \text{int } \Theta$.

Démonstration. Soit $F_{\theta_0}^T$ la fonction de répartition de $T(X^{(n)})$ sous \mathbb{P}_{θ_0} . Comme pour le Théorème 3.9, on a :

$$\mathbb{E}_{\theta_0}^{(n)}[\phi_{*T}^+(X^{(n)})] = 1 - F_{\theta_0}^T(t_\alpha^+) + \gamma_\alpha(F_{\theta_0}(t_\alpha^+) - \lim_{\varepsilon \rightarrow 0} F_{\theta_0}^T(t_\alpha^+ - \varepsilon)),$$

d'où on distingue deux cas :

— s'il existe z_α t.q. $F_{\theta_0}^T(z_\alpha) = 1 - \alpha$, on prend :

$$(t_\alpha^+, \gamma_\alpha) := (z_\alpha, 0),$$

— et sinon, on pose :

$$t_\alpha^+ := \inf\{z \in \mathbb{R} \text{ t.q. } F_{\theta_0}^T(z) \geq 1 - \alpha\},$$

et :

$$\gamma_\alpha := \frac{F_{\theta_0}^T(t_\alpha^+) - (1 - \alpha)}{\lim_{\varepsilon \rightarrow 0} F_{\theta_0}^T(t_\alpha^+) - F_{\theta_0}^T(t_\alpha^+ - \varepsilon)} \in (0, 1).$$

Pour le second point, on prend $\theta', \theta'' \in \Theta$ tels que $\theta' < \theta''$. On réécrit :

$$\begin{aligned} \phi_{*T}^+(x^{(n)}) &= \begin{cases} 1 & \text{si } h_{\theta', \theta''}(T(x^{(n)})) > h_{\theta', \theta''}(t_\alpha^+) \\ \gamma_\alpha & \text{si } h_{\theta', \theta''}(T(x^{(n)})) = h_{\theta', \theta''}(t_\alpha^+) \\ 0 & \text{sinon} \end{cases} \\ &= \begin{cases} 1 & \text{si } L_{\theta''}(x^{(n)}) > h_{\theta', \theta''}(t_\alpha^+) L_{\theta'}(x^{(n)}) \\ \gamma_\alpha & \text{si } L_{\theta''}(x^{(n)}) = h_{\theta', \theta''}(t_\alpha^+) L_{\theta'}(x^{(n)}) \\ 0 & \text{sinon} \end{cases} \end{aligned}$$

On trouve que ϕ_{*T}^+ est le test de Neyman du problème d'hypothèse :

$$\begin{cases} H_0 : \theta = \theta' \\ H_1 : \theta = \theta'' \end{cases}$$

au niveau $\mathbb{E}_{\theta'}[\phi_{*T}^+(X^{(n)})]$. Le théorème précédent donne donc :

$$\mathbb{E}_{\theta'}[\phi_{*T}^+(X^{(n)})] < \mathbb{E}_{\theta''}[\phi_{*T}^+(X^{(n)})].$$

Pour le dernier point, soient $\theta_1 > \theta_0$ et ϕ , un test de niveau α pour le problème d'hypothèse (3.4). θ_1 étant choisi arbitrairement, on a que ϕ_{*T}^+ est de niveau α pour le problème d'hypothèse :

$$\begin{cases} H_0 : \theta = \theta_0 \\ H_1 : \theta > \theta_0 \end{cases} \quad (3.5)$$

car ϕ_{*T}^+ est à PUM de niveau α pour le problème d'hypothèse (3.3).

Par choix de ϕ , on sait en particulier que ϕ est de niveau α pour (3.5). ϕ_{*T}^+ domine donc ϕ uniformément en puissance. Puisque ϕ_{*T}^+ est de niveau α pour (3.4), on a ϕ_{*T}^+ à PUM pour (3.4). \square

Théorème 3.13. Soit un modèle statistique à rapport de vraisemblance pour la statistique $T(x^{(n)})$ et soit $\alpha \in (0, 1)$. Alors :

— $\exists (t_{\alpha}^-, \gamma_{\alpha}) \in \mathbb{R} \times [0, 1]$ t.q. ϕ_{*T}^- défini par :

$$\phi_{*T}^-(x^{(n)}) = \begin{cases} 1 & \text{si } T(x^{(n)}) < t_{\alpha}^- \\ \gamma_{\alpha} & \text{si } T(x^{(n)}) = t_{\alpha}^- \\ 0 & \text{sinon} \end{cases}$$

vérifie $\mathbb{E}_{\theta_0}^{(n)}[\phi_{*T}^-(X^{(n)})] = \alpha$;

— la fonction $\theta \mapsto \mathbb{E}_{\theta}^{(n)}[\phi_{*T}^-]$ est strictement décroissante ;

— le test ϕ_{*T}^- est à PUM dans la classe des tests de niveau α pour le problème :

$$\begin{cases} H_0 : \theta \geq \theta_0 \\ H_1 : \theta < \theta_0 \end{cases} \quad (3.6)$$

3.3 Tests bilatéraux

Théorème 3.14. En considérant un modèle à rapport de vraisemblance monotone, pour tout $\alpha \in (0, 1)$, il n'existe pas de test à PUM au niveau α pour le problème d'hypothèse (3.2).

Démonstration. Supposons par l'absurde qu'il existe ϕ_{*T} à PUM maximal au niveau α . On fixe $\theta_1 > \theta_0$. ϕ_{*T} est de niveau α pour le problème, et donc, on a :

$$\mathbb{E}_{\theta_1}[\phi_{*T}] \geq \mathbb{E}_{\theta_1}[\phi_{*T}^+],$$

avec ϕ_{*T}^+ , test de Neyman pour le problème (3.3) au niveau α . On déduit donc :

$$\mathbb{E}_{\theta_1}[\phi_{*T}] = \mathbb{E}_{\theta_1}[\phi_{*T}^+].$$

Et puisque ϕ_{*T} est de niveau α pour le problème (3.3), et est de même puissance que ϕ_{*T}^+ , on déduit (Théorème 3.10) qu'il existe $\gamma_\alpha : \mathcal{X}^{(n)} \rightarrow [0, 1]$ et $k_\alpha \in \mathbb{R}$ tels que :

$$\phi_{*T}(x^{(n)}) = \begin{cases} 1 & \text{si } L_{\theta_1}^{(n)}(x^{(n)}) > k_\alpha L_{\theta_0}^{(n)}(x^{(n)}) \\ \gamma_\alpha(x^{(n)}) & \text{si } L_{\theta_1}^{(n)}(x^{(n)}) = k_\alpha L_{\theta_0}^{(n)}(x^{(n)}) \\ 0 & \text{sinon.} \end{cases}$$

Le modèle étant à RVM, on peut montrer que $\theta \mapsto \mathbb{E}_\theta[\phi_{*T}]$ est strictement croissante (voir Théorème 3.12). Par conséquent, pour $\theta < \theta_0$:

$$\mathbb{E}_\theta[\phi_{*T}] \leq \mathbb{E}_{\theta_0}[\phi_{*T}] = \alpha = \mathbb{E}_{\theta_0}[\phi_{*T}^+] < \mathbb{E}_\theta[\phi_{*T}^+],$$

ce qui contredit le fait que ϕ_{*T} soit de PUM. □

3.3.1 Tests sans biais

Définition 3.15. Le test ϕ de niveau $\alpha \in (0, 1)$ pour le problème (3.1) est dit *sans biais* lorsque :

$$\forall \theta \in \Theta_1 : \mathbb{E}_\theta[\phi] \geq \alpha.$$

Remarque. Pour les problèmes considérés ici (tests bilatéraux sous la forme (3.2)), les tests ϕ admissibles sont donc les tests sans biais, c-à-d tels que $\mathbb{E}_{\theta_0}[\phi] \leq \alpha$ et pour tout $\theta \neq \theta_0$ (et donc $\in \Theta_1 = \Theta_0 \setminus \{\theta_0\}$) $\mathbb{E}_\theta[\phi] \geq \alpha$. On note donc que $\theta \mapsto \mathbb{E}_\theta[\phi]$ continue implique $\mathbb{E}_{\theta_0}[\phi] = 0$.

Cette définition permet de ne plus avoir les estimateurs ϕ_{*T}^+ et ϕ_{*T}^- . En effet, leur fonction de puissance $\theta \mapsto \mathbb{E}_\theta[\Phi]$ pour $\Phi \in \{\phi_{*T}^+, \phi_{*T}^-\}$ sont strictement croissantes. Donc pour tout $\theta < \theta_0$, on a $\mathbb{E}_\theta[\Psi] < \alpha$.

Remarque. Notons alors, pour $\alpha \in (0, 1)$, \mathfrak{B}_α la classe des tests sans biais au niveau α .

Théorème 3.16. Soit un modèle statistique à RVM tel que les vraisemblances s'écrivent sous la forme :

$$L_\theta^{(n)}(x^{(n)}) = c_\theta h(x^{(n)}) \exp(\theta T(x^{(n)})).$$

Soit $\alpha \in (0, 1)$ et soit le problème (3.2). Alors :

— $\exists (t_\alpha^1, t_\alpha^2) \in \mathbb{R}^2$ et $(\gamma_\alpha^1, \gamma_\alpha^2) \in [0, 1]^2$ tels que le test ϕ_{*T} défini par :

$$\phi_{*T}(x^{(n)}) = \begin{cases} 1 & \text{si } T(x^{(n)}) \notin [t_\alpha^1, t_\alpha^2] \\ \gamma_\alpha^1 & \text{si } T(x^{(n)}) = t_\alpha^1 \\ \gamma_\alpha^2 & \text{si } T(x^{(n)}) = t_\alpha^2 \\ 0 & \text{sinon} \end{cases}$$

vérifie $\mathbb{E}_{\theta_0}[\phi_{*T}] = \alpha$ et $\mathbb{E}_{\theta_0}[\phi_{*T} \cdot T] = \alpha \cdot \mathbb{E}_{\theta_0}[T]$;

— ϕ_{*T} est à PUM dans \mathfrak{B}_α pour le problème donné.

Remarque. Un tel modèle paramétrique est donc à RVM en la statistique T .

3.4 Tests de rapport de vraisemblance

Définition 3.17. On définit le rapport de vraisemblance suivant, noté Λ :

$$\Lambda : \mathcal{X}^{(n)} \rightarrow [0, 1] : x^{(n)} \mapsto \Lambda(x^{(n)}) := \frac{\sup_{\theta \in \Theta_0} L_\theta^{(n)}(x^{(n)})}{\sup_{\theta \in \Theta} L_\theta^{(n)}(x^{(n)})}.$$

Théorème 3.18. Soit un modèle statistique avec $\Theta \subset \mathbb{R}^k$, avec $r \leq k$ paramètres indépendants. Sous certaines hypothèses de régularité, on a :

$$\forall \theta \in \Theta_0 : -2 \log \Lambda(X^{(n)}) \xrightarrow[n \rightarrow +\infty]{\mathcal{D}} \chi_{k-r}^2.$$

3.5 Tests χ^2

3.5.1 Loi multinomiale

Soit une expérience aléatoire E à valeurs dans $\{A_1, \dots, A_k\}$ de probabilités p_1, \dots, p_k .

Définition 3.19. Soit $N = (N_1, \dots, N_k) \in \mathbb{N}^k$ tel que $\sum_{i=1}^k N_i = n$, où n est le nombre d'expériences indépendantes de l'expérience E . (N_i désigne le nombre d'occurrences de A_i). La loi du vecteur aléatoire N est dite *multinomiale* de paramètres n, p_1, \dots, p_{k-1} . On note alors :

$$N \sim \text{Mult}(n, p_1, \dots, p_{k-1}).$$

Remarque. Pour $1 \leq i \leq k$, on a $N_i \sim \text{Bin}(n, p_i)$, d'où le nom de multinomiale. On en déduit :

$$\text{Var}[N_i] = np_i(1 - p_i).$$

Prenons $i \neq j$. Par stabilité des binomiales, on trouve :

$$\text{Var}[N_i + N_j] = n(p_i + p_j)(1 - (p_i + p_j)) = np_i - np_i^2 - 2np_i p_j + np_j - np_j^2,$$

et :

$$\begin{aligned} \text{Var}[N_i + N_j] &= \text{Var}[N_i] + \text{Var}[N_j] + 2 \text{Cov}[N_i, N_j] = np_i(1 - p_i) + np_j(1 - p_j) + 2 \text{Cov}[N_i, N_j] \\ &= np_i - np_i^2 + np_j - np_j^2 + 2 \text{Cov}[N_i, N_j]. \end{aligned}$$

On en déduit :

$$\text{Cov}[N_i, N_j] = -np_i p_j.$$

On observe alors une dépendance entre N_i et N_j , et avec une corrélation négative.

Théorème 3.20. Soit $N \sim \text{Mult}(n, p_1, \dots, p_{k+1})$. Alors :

$$\sum_{i=1}^k \frac{(N_i - np_i)^2}{np_i} \xrightarrow[n \rightarrow +\infty]{\mathcal{D}} \chi_{k-1}^2.$$

Théorème 3.21. Soit $N \sim \text{Mult}(n, p_1(\theta), \dots, p_{k-1}(\theta))$, avec $\theta \in \Theta \subseteq \mathbb{R}^d$ t.q. $\text{int } \Theta \neq \emptyset$. Si $\hat{\theta}$ est l'estimateur du maximum de vraisemblance de θ , alors :

$$\sum_{i=1}^k \frac{(N_i - np_i(\hat{\theta}))^2}{np_i(\hat{\theta})} \xrightarrow[n \rightarrow +\infty]{\mathcal{D}} \chi_{k-1-d}^2 \text{ sous } \mathbb{P}_\theta \forall \theta \in \Theta.$$

Remarque. Il est commun d'utiliser ces propriétés de convergence pour approximer N à l'aide de χ^2 à partir du moment où :

- $n \geq 30$;
- $\forall i \in \{1, \dots, k\} : np_i \geq 1$;
- $\left| \{i \in \{1, \dots, k\} \text{ t.q. } np_i \geq 5\} \right| \geq 0.8k$.

3.5.2 Tests d'ajustement et d'adéquation

Notons $p = (p_1, \dots, p_k)$ le vecteur de probabilités d'une variable multinomiale. On dénotera par $\bar{p} \in [0, 1]^k$ un vecteur de probabilités fixé (donc tel que $\langle \bar{p}, \mathbf{1} \rangle = 1$). Intéressons-nous au problème d'hypothèse :

$$\begin{cases} H_0 : p = \bar{p} \\ H_1 : p \neq \bar{p} \end{cases} \quad (3.7)$$

Définition 3.22. Désignons par $\chi_{\ell, \alpha}^2$ le quantile d'ordre α d'une variable χ^2 à ℓ degrés de liberté.

Par le Théorème 3.20, on définit la statistique suivante :

$$Q^{(n)} = Q^{(n)}(N) := \sum_{i=1}^k \frac{(N_i - \bar{p}_i)^2}{n\bar{p}_i},$$

justifiée par le fait que sous H_0 , $n\bar{p}_i = \mathbb{E}[N_i]$.

Remarque. Cette statistique peut-être vue comme une certaine *distance* entre N et H_0 .

Pour $\alpha \in (0, 1)$, on définit alors le test pur :

$$\phi_{\alpha, Q^{(n)}} : \mathcal{N} \rightarrow \{0, 1\} : N \mapsto \begin{cases} 1 & \text{si } Q^{(n)}(N) > \chi_{k-1, 1-\alpha}^2 \\ 0 & \text{sinon,} \end{cases}$$

qui donc rejette H_0 lorsque la valeur de $Q^{(n)}$ est *trop grande*, c-à-d au-delà du seuil déterminé par le quantile d'ordre $1 - \alpha$.

Remarque. Le théorème 3.20 implique que ce test $\phi_{\alpha, Q^{(n)}}$ est asymptotiquement de niveau α .

Afin de ne pas recalculer systématiquement $\chi_{k-1, 1-\alpha}^2$ pour différentes valeurs de $\alpha \in (0, 1)$, on définit la p-valeur.

Définition 3.23. La p-valeur définie par :

$$\text{p-valeur} := P_{H_0}^{(n)}[Q^{(n)} \geq q^{(n)}],$$

avec $q^{(n)}$ la valeur calculée de la statistique $Q^{(n)}$ est un indicateur d'acceptation de l'hypothèse nulle.

Remarque. La p-valeur $\in [0, 1]$ donne une idée de la présomption d'une hypothèse nulle fausse. De faibles valeurs pour p-valeur (de l'ordre de $< 10^{-2}$) indiquent un très haute présomption d'hypothèse nulle fausse, alors que de hautes valeurs (de l'ordre de $> 10^{-1}$) indiquent qu'il n'y a pas de présomption d'hypothèse nulle fausse.

Attention : une haute p-valeur ne veut pas dire que l'hypothèse nulle est vraie, mais qu'il est peu probable qu'elle soit à rejeter.

Le problème d'hypothèse (3.7) peut être élargi à un modèle paramétrique de la forme :

$$\begin{cases} H_0 : \exists \theta \in \Theta \text{ t.q. } p = p(\theta) \\ H_1 : \forall \theta \in \Theta : p \neq p(\theta) \end{cases} \quad (3.8)$$

avec $\Theta \subset \mathbb{R}^d$ tel que $\text{int } \Theta \neq \emptyset$.

On définit alors la statistique :

$$Q^{(n)} = Q^{(n)}(N) := \sum_{i=1}^k \frac{(N_i - np_i(\hat{\theta}))^2}{np_i(\hat{\theta})}.$$

Pour cette nouvelle statistique, le test $\phi_{\alpha, Q^{(n)}}$ est à nouveau asymptotiquement de niveau α pour le problème (3.8), par le Théorème 3.21.

3.5.3 Tests d'homogénéité

Les tests d'homogénéité correspondent aux situations de vecteurs de multinomiales :

$$N = (N_1, \dots, N_\ell) \quad \text{t.q.} \quad \forall 1 \leq j \leq \ell : N_j = (N_{1j}, \dots, N_{kj}).$$

Définition 3.24. Un test d'homogénéité est un problème d'hypothèse sous la forme :

$$\begin{cases} H_0 : \forall i \in \llbracket 1, k \rrbracket : \forall j \in \llbracket 2, \ell \rrbracket : p_{i,j-1} = p_{i,j} \\ H_1 : \exists (i, j) \in \llbracket 1, k \rrbracket \times \llbracket 2, \ell \rrbracket \text{ t.q. } p_{i,j-1} \neq p_{i,j}. \end{cases} \quad (3.9)$$

Dans un tel cas, par indépendance des N_j , on étend le Théorème 3.20 en :

$$\sum_{j=1}^{\ell} \sum_{i=1}^k \frac{(N_{ij} - n_j p_{ij})^2}{n_j p_{ij}} \xrightarrow[n \rightarrow +\infty]{\mathcal{D}} \chi_{\ell \cdot (k-1)}^2.$$

Les χ^2 étant des sommes de normales, sommer des χ^2 , donne une χ^2 avec pour nombre de degrés de liberté la somme des degrés de liberté des variables sommées.

Sous l'hypothèse nulle, les p_{ij} sont constantes selon j , et donc la convergence peut être reformulée en :

$$\sum_{i=1}^k \sum_{j=1}^{\ell} \frac{(N_{ij} - n_j p_i)^2}{n_j p_i} \xrightarrow[n \rightarrow +\infty]{\mathcal{D}} \chi_{\ell \cdot (k-1)}^2,$$

avec p_i l'unique valeur selon les j tels que $\sum_i p_i = 1$.

Les estimateurs de maximum de vraisemblance des p_i sont donnés par :

$$\hat{p}_i = \frac{N_{i\cdot}}{n} := \frac{1}{n} \sum_{j=1}^{\ell} N_{ij}.$$

En considérant les $k - 1$ valeurs p_i comme indépendantes, sous H_0 , et par le Théorème 3.21, on a :

$$\sum_{i=1}^k \sum_{j=1}^{\ell} \frac{(N_{ij} - n_j \hat{p}_i)^2}{n_j \hat{p}_i} = \sum_{i=1}^k \sum_{j=1}^{\ell} \frac{\left(N_{ij} - \frac{n_j N_{i\cdot}}{n} \right)^2}{\frac{n_j N_{i\cdot}}{n}} \xrightarrow[n \rightarrow +\infty]{\mathcal{D}} \chi_{(k-1)(\ell-1)}^2.$$

On définit alors le test pur de niveau asymptotique $\alpha \in (0, 1)$:

$$\phi_\alpha : N \mapsto \begin{cases} 1 & \text{si } \sum_{i=1}^k \sum_{j=1}^{\ell} \frac{n \left(N_{ij} - \frac{n_j N_{i\cdot}}{n} \right)^2}{n_j N_{i\cdot}} > \chi_{(k-1)(\ell-1), 1-\alpha}^2 \\ 0 & \text{sinon} \end{cases}$$

3.5.4 Tests d'indépendance

Pour un test d'indépendance, il faut un vecteur aléatoire (X, Y) avec X ayant k valeurs possibles, et Y , ℓ valeurs pour $k, \ell \geq 2$.

On définit la distribution jointe par les p_{ij} , $(i, j) \in \llbracket 1, k \rrbracket \times \llbracket 1, \ell \rrbracket$.

Définition 3.25. On définit les distributions marginales par :

$$p_{i\cdot} = \mathbb{P}[X = x_i] = \sum_{j=1}^{\ell} p_{ij} \quad \text{et} \quad p_{\cdot j} = \mathbb{P}[Y = y_j] = \sum_{i=1}^k p_{ij}.$$

Le but d'un test d'indépendance est d'avoir pour hypothèse nulle l'indépendance des n observations iid $(X_t, Y_t), 1 \leq t \leq n$:

$$\begin{cases} H_0 : \forall (i, j) \in \llbracket 1, k \rrbracket \times \llbracket 1, \ell \rrbracket : p_{ij} = p_{i\cdot} p_{\cdot j} \\ H_1 : \exists (i, j) \in \llbracket 1, k \rrbracket \times \llbracket 1, \ell \rrbracket \text{ t.q. } p_{ij} \neq p_{i\cdot} p_{\cdot j}. \end{cases} \quad (3.10)$$

À nouveau, selon H_0 , on a :

$$\sum_{i=1}^k \sum_{j=1}^{\ell} \frac{(N_{ij} - np_{i\cdot} p_{\cdot j})^2}{np_{i\cdot} p_{\cdot j}} \xrightarrow[n \rightarrow +\infty]{\mathcal{D}} \chi_{(k\ell)-1}^2.$$

Les estimateurs de maximum de vraisemblance étant :

$$\hat{p}_{i\cdot} = \frac{N_{i\cdot}}{n} \quad \text{et} \quad \hat{p}_{\cdot j} = \frac{N_{\cdot j}}{n},$$

on a alors, sous H_0 toujours :

$$\sum_{i=1}^k \sum_{j=1}^{\ell} \frac{N \left(N_{ij} - \frac{N_{i\cdot} N_{\cdot j}}{N} \right)^2}{N_{i\cdot} N_{\cdot j}} \xrightarrow[n \rightarrow +\infty]{\mathcal{D}} \chi_{(k-1)(\ell-1)}^2.$$

Pour $\alpha \in (0, 1)$, le test est alors défini par :

$$\phi_{\alpha} : N \mapsto \begin{cases} 1 & \text{si } \sum_{i=1}^k \sum_{j=1}^{\ell} \frac{N \left(N_{ij} - \frac{N_{i\cdot} N_{\cdot j}}{N} \right)^2}{N_{i\cdot} N_{\cdot j}} > \chi_{(k-1)(\ell-1), 1-\alpha}^2 \\ 0 & \text{sinon} \end{cases}$$

et est de niveau asymptotique α .